

Corso di Laurea in Ingegneria e Scienze Informatiche

Fancy Title

Tesi di laurea in:
SUPERVISOR'S COURSE NAME

Relatore

Golfarelli Matteo

Candidato

Ventura Elettra

Correlatore

Montagna Sara

Abstract

Max 2000 characters, strict.

Optional. Max a few lines.

Contents

Abstract	iii
1 Introduction	1
2 Il pipeline di sviluppo farmaceutico	3
2.1 Le fasi del Drug Development	3
2.1.1 Screening dei composti	4
2.2 Attrition Rate e impatto economico	6
2.3 Il ruolo dell'AI nella pipeline	7
3 Rappresentazione molecolare e machine readability	9
3.1 Lettura di dati chimici e biologici in informatica	9
3.2 Rappresentazioni lineari: SMILES e SELFIES	10
3.2.1 SMILES	10
3.2.2 SELFIES	11
3.3 Fingerprint molecolari	13
3.3.1 Esempi di fingerprints	14
3.4 Rappresentazione a grafo	16
3.5 Embedding molecolari e modelli pre-addestrati	17
4 DTI e DTA	19
4.1 Target Prediction	19
4.2 Drug Target Interaction (DTI)	20
4.2.1 Rappresentazione degli input	22
4.3 Metodologie di Predizione	22
4.3.1 Docking Molecolare	23
4.3.2 Machine Learning (ML) e Deep Learning (DL)	23
4.3.3 GNN per molecole	27
5 ADMET	29
5.1 Il framework ADMET	29

CONTENTS

5.2	La tossicità molecolare	29
5.3	Evoluzione verso il Machine Learning per la predizione ADMET . .	30
5.4	Multimodalità e meccanismi di Attention	31
6	State of the art	33
6.1	Some cool topic	33
7	Contribution	35
7.1	Fancy formulas here	35
		37
	Bibliography	37

List of Figures

3.1	Rappresentazione SMILES e struttura molecolare del Climbazolo. .	11
3.2	Confronto tra le notazioni per il benzene: SMILES (sopra) e SELF- IES (sotto) [KAB ⁺ 22].	12
3.3	Struttura chimica dell'Ibuprofene. Indici dei bit attivi rilevati: [74, 115, 123, 139, 141, 149, 154, 155, 157, 159, 160, 162, 163, 164, 165]	15
3.4	Primi 100 bit del fingerprint dell'Ibuprofene	16
3.5	Rappresentazione topologica non orientata $G = (V, E)$ dell'Ibuprofene generata da codice grazie a librerie RDKit e NetworkX.	17
6.1	Some random image	33

LIST OF FIGURES

List of Listings

3.1 Estrazione delle MACCS Keys tramite RDKit	15
listings/HelloWorld.java	35

LIST OF LISTINGS

Chapter 1

Introduction

Write your intro here.

You can use acronyms that you defined previously, such as Internet of Things (IoT). If you use acronyms twice, they will be written in full only once (indeed, you can mention the IoT now without it being fully explained). In some cases, you may need a plural form of the acronym. For instance, that you are discussing Virtual Machines (VMs), you may need both VM and VMs.

Ventura Elettra: Add sidenotes in this way. They are named after the author of the thesis

Structure of the Thesis

Ventura Elettra: At the end, describe the structure of the paper

Chapter 2

Il pipeline di sviluppo farmaceutico

2.1 Le fasi del Drug Development

Lo sviluppo di un nuovo farmaco è un processo complesso e delicato, che si articola in più fasi sequenziali, ciascuna delle quali introduce vincoli tecnici, economici e regolatori che rendono l'intero percorso lungo, dispendioso e ad alto rischio di fallimento [ZYW⁺25].

Negli ultimi due decenni si è distinta come principale strategia di discovery la **Target Based Drug Discovery** [KG23] (**TBDD**), processo che ha come inizio l'**identificazione del target**, ovvero la selezione di molecole biologiche, tipicamente proteine o acidi nucleici, la cui modulazione risulti rilevante per la malattia di interesse (ovvero target *druggable*, trattabili farmalogicamente). Si tratta del primo filtro a cui vengono sottoposte le molecole candidate ed è proprio il primo "collo di bottiglia" del processo di ricerca. Gli svariati approcci di screening utilizzati in questa fase di *identification* possono essere classificati in quattro gruppi principali [RRS⁺22]:

- Approcci "diretti" o basati sull'**affinità** tra proteine e piccole molecole.
- Approcci basati sul **fenotipo**, usati per effettuare comparazioni tra i profili biologici delle molecole e quelli di farmaci già noti, di cui si conosce il comportamento.

- Approcci basati sull'individuazione dei **geni** specifici responsabili di farmacoresistenza da parte delle molecole.
- Approcci **computazionali**, in grado di fare previsioni sui target sulla base della complementarietà chimica dei candidati.

Sebbene molti di questi metodi, come l'*affinity pull-down* e il *whole-genome knock-down* siano ampiamente usati e rimangano i pilastri per la validazione dei target di interesse, questi presentano limiti intrinseci in termini di efficacia e costi.

Seguono le fasi di **drug discovery** vero e proprio, che si pongono l'obiettivo di identificare gli **hits**, farmaci in grado di interagire con i target precedentemente individuati. I geni candidati vengono espressi in grandi quantità in organismi poco complessi tramite la tecnologia del DNA ricombinante, permettendo lo **High-Throughput Screening** (HTS), ovvero uno screening ad alta velocità che agisce su vaste e variegate librerie chimiche [KG23].

Sebbene l'HTS sia più performante in termini di costi rispetto ai metodi manuali, non si è dimostrato in grado di garantire la sicurezza o l'efficacia della molecola su organismi più complessi. Per superare tali limiti, emerge la necessità di tecniche di **Virtual Screening** (VS), che permettono di pre-selezionare *in silico* i composti più promettenti, riducendo drasticamente il numero di test fisici necessari.

2.1.1 Screening dei composti

Il processo di screening rappresenta lo strumento per "setacciare" le librerie chimiche nella ricerca delle giuste interazioni biochimiche. Il **VS** si distingue dall'HTS per la sua capacità di andare oltre i limiti della ricerca fisica attuabile in laboratorio, valutando computazionalmente composti appartenenti a librerie fisiche o sintetizzabili su richiesta [CL24]. Questo approccio si divide in due macro-famiglie:

- I metodi **ligand-based**, che si basano sull'ipotesi che molecole con proprietà simili a ligandi noti presentino attività biologica analoga. Tra questi, la **pharmacophore searching** identifica composti compatibili al target per caratteristiche chimico-spaziali (come la presenza di donatori e accettori di idrogeno o di gruppi aromatici in determinate posizioni) [McI07].

- I metodi **structure-based**, che sfruttano la struttura tridimensionale del target tramite strumenti come il **molecular docking** o l'**ensemble docking**, quest'ultimo è un'evoluzione del primo che valuta il ligando su molteplici conformazioni del recettore, ottenendo così risultati più robusti rispetto all'approssimazione del recettore singolo e rigido.

Il virtual screening accelerato dal Machine Learning rappresenta una risposta al crescente e sempre più insostenibile peso computazionale del docking. Questo approccio prevede che un modello di ML venga addestrato sui risultati del docking su un sottoinsieme della libreria (si usano librerie dette "ultra-large") e che impari a predire i punteggi del docking per i composti incogniti, senza eseguire il calcolo fisico. Questo approccio può portare a una riduzione di 100 volte il numero di composti da sottoporre a docking esplicito, mantenendo comunque un arricchimento dei composti top-scoring paragonabile allo screening esaustivo [CL24].

La *hit discovery* è tuttavia solo il primo passaggio del processo di *lead generation*, o *Hit to Lead* (H2L), che si pone di valutare i composti individuati dalle *hits* non solo per la loro presenza di attività, ma per la qualità della loro interazione con il target. In questa fase vengono analizzate potenza, selettività e proprietà fisico-chimiche di base, causando una scrematura che può apportare un miglioramento del legame chimico hit-target dell'ordine di grandezza nanomolare [BGF⁺22]. La fase finale di drug discovery è la *Lead Optimization* (LO), che interviene per accentuare caratteristiche desiderate nei composti lead selezionati, o per correggere i difetti strutturali che impedirebbero ad essi di superare i trial clinici. La LO moderna è un processo razionale guidato da metodi computazionali che includono studi farmacoforici, docking molecolare (metodo utilizzato per prevedere l'orientamento di un ligando su un recettore per la formazione di un complesso stabile), dinamica molecolare (simulazioni con lo scopo di ottenere dati sulle proprietà fisico-strutturali delle molecole) e QSAR. In particolare, il **QSAR** (Quantitative Structure-Activity Relationship) rappresenta un approccio di modellazione statistica volto a correlare le caratteristiche strutturali con l'attività biologica dei composti, evolvendosi oggi in modelli di Machine Learning capaci di interpretare e prevedere queste caratteristiche per generare risultati nuovi [BGF⁺22].

Una volta ottenute le lead ottimizzate si può passare agli **studi pre-clinici**,

condotti su modelli animali per valutare sicurezza ed efficacia dei farmaci, prima che questi vengano testati sull'essere umano. La fase successiva, quella degli effettivi **trial clinici**, si articola a sua volta in tre stadi progressivi:

- La fase I verifica la sicurezza del composto su un piccolo gruppo di soggetti sani;
- La fase II ne valuta l'efficacia su pazienti affetti dalla patologia interessata;
- La fase III, condotta su popolazioni più ampie, costituisce il test definitivo richiesto per l'approvazione regolatoria.

Al termine di questo percorso, il farmaco approvato entra nella fase di **post-market surveillance**, in cui vengono monitorati nel lungo periodo gli effetti collaterali e la stabilità della formulazione.

2.2 Attrition Rate e impatto economico

Il percorso che racchiude queste fasi è caratterizzato da un problema fondamentale: nonostante l'accelerazione in ambito tecnologico degli ultimi anni e la comparsa di nuovi strumenti computazionali ad ausilio del processo, il successo delle fasi cliniche rimane un obiettivo estremamente difficile da raggiungere. Questo fenomeno è descritto dall'**attrition rate**, ovvero il tasso di riduzione ("logoramento") del numero di candidati farmaci durante l'avanzamento della pipeline. Delle migliaia di molecole potenziali individuate dalla prima fase di discovery, solo una piccola frazione sopravvive ai test clinici e meno del 10% dei composti che entrano nel primo step di trial raggiunge l'approvazione finale dalle autorità regolatorie.

Questo elevato tasso di insuccesso si traduce in elevatissimi costi economici. Lo sviluppo di un nuovo farmaco richiede oggi un investimento medio di circa **2,6 miliardi di dollari americani** e un arco temporale compreso tra i dodici e i quindici anni [ZYW⁺25]. Inoltre, anche il ritorno economico per le industrie farmaceutiche è drasticamente calato: nell'arco di un decennio, per ogni dollaro investito in ricerca il ritorno economico è crollato drasticamente, passando da 10 a meno di 2 centesimi [Fre].

Le cause di questo elevato tasso di fallimento sono molteplici. In primo luogo, molti farmaci per malattie comuni e con meccanismi biologici noti sono già stati scoperti; ciò che rimane da esplorare riguarda patologie più rare e complesse, dove l'identificazione di molecole target risulta più difficile [Fre]. Inoltre, la selezione delle molecole nelle fasi di *discovery* può essere basata su parametri troppo semplici e poco esaustivi. Infatti, come evidenziato da **Kenakin** [Ken24], la mancanza di efficacia clinica e i problemi di sicurezza legati alla tossicità rimangono le cause primarie del logoramento dei candidati farmaci, ed entrambi sono imputabili a una descrizione farmacologica superficiale e poco approfondita dei **lead** stessi.

2.3 Il ruolo dell'AI nella pipeline

L'integrazione dell'Intelligenza Artificiale (AI) e del Deep Learning (DL) ha trasformato la pipeline di ricerca farmaceutica da un processo basato su "trial and error" a un percorso più disciplinato, guidato dalla raccolta e dall'analisi dei dati biologici [ZYW⁺25]. Questi strumenti vengono impiegati trasversalmente, in ciascuna delle diverse fasi più delicate e "logoranti" del processo.

Nella fase di **target identification**, l'AI sta affiancando e in alcuni casi sostituendo i metodi tradizionali di screening, prima basati sull'analisi dettagliata dell'affinità tra molecole. Il nuovo approccio consiste nel rappresentare i geni per la loro *funzione biologica*, analogamente alle tecniche di *word embedding* sviluppate nel Natural Language Processing (NLP). Negli step successivi dello sviluppo del composto, il contributo più significativo si osserva nella predizione dei comportamenti di interazione farmaco-proteina (DPI). Queste stime sono solitamente compiute su uno spazio chimico di scala molto ampia, e richiedono l'analisi di molte interazioni ancora sconosciute. Proprio per questo, i modelli di Machine Learning vengono addestrati in modalità semi-supervisionato per etichettare queste interazioni incognite, integrando efficacemente informazioni eterogenee, quali la struttura chimica del composto, i dati genomici e le reti di interazione. L'importanza di affinare tali modelli risiede nella necessità di colmare il *knowledge gap* relativo agli effetti collaterali: è stato infatti stimato che circa 1.000 proteine umane siano potenzialmente responsabili di tossicità *off-target*.

Identificare precocemente queste interazioni impreviste risulta dunque fonda-

mentale per prevedere e mitigare interazioni nocive già nelle fasi preliminari dello sviluppo in silico [?].

Chapter 3

Rappresentazione molecolare e machine readability

3.1 Lettura di dati chimici e biologici in informatica

L'applicazione di tecniche di Intelligenza Artificiale nell'ambito biochimico richiede il passaggio fondamentale da dati chimici a dati computazionali. Questi ultimi non devono essere semplicemente informazioni biologiche tradotte digitalmente, ma devono essere presentate in formati effettivamente elaborabili da algoritmi e tecnologie di ML [JPS22].

Storicamente, i risultati venivano registrati in forma cartacea, portando alla perdita di una vasta mole di dati non pubblicati. Al giorno d'oggi, invece, sebbene la quasi totalità degli strumenti di laboratorio sia in grado di rappresentare e salvare i dati in forma digitale (e accessibile ad altri ricercatori), una parte significativa di questi dati chimici resta in formati analogici o non accessibili automaticamente dagli agenti computazionali.

Risulta quindi necessaria, per sopperire a questa frammentazione di dati, una transizione verso una scienza più aperta, che integri l'implementazione di dati *machine-actionable*, ovvero adatti all'automatizzazione computazionale. In questo contesto, la rappresentazione molecolare deve raggiungere un *trade-off* tra completezza informativa e complessità. Infatti, sebbene formati altamente strutturati,

in grado di descrivere esaustivamente le proprietà chimiche, geometriche e funzionali delle molecole, si dimostrano ideali per modelli di ML, questi possono risultare estremamente onerosi per il lavoro dei chimici in laboratorio.


Senza una rappresentazione standardizzata che rispetti i principi **FAIR** (*Findable, Accessible, Interoperable, Reusable*), l'efficacia dei modelli di Deep Learning nella previsione delle proprietà molecolari risulterebbe superficiale rispetto alla complessità dei sistemi chimici e limitata dalla qualità del dato in ingresso, escludendo per esempio previsioni riguardo le condizioni di reazione o la sintetizzabilità [JPS22].

3.2 Rappresentazioni lineari: SMILES e SELFIES

La necessità di disporre di dati FAIR e *machine readable/actionable* ha portato allo sviluppo di diverse metodologie di codifica di dati chimici in formati meno complessi, processabili da algoritmi e metodi di machine learning.

3.2.1 SMILES

Il sistema **SMILES** (Simplified Molecular-Input Line-Entry System) rappresenta oggi lo standard più diffuso per la rappresentazione di molecole chimiche nell'ambito delle applicazioni di intelligenza artificiale. Si basa sulla descrizione di strutture chimiche attraverso stringhe di caratteri alfanumerici ASCII [ATLO24], sottoponibili a processi NLP. Una stringa SMILES rappresenta la molecola come una catena di atomi, dove le ramificazioni sono indicate tra parentesi tonde, le chiusure degli anelli da numeri corrispondenti (per esempio, 1 con 1, ecc...), i simboli "-", "=", "#", [SBF⁺24] rappresentano diversi tipi di legame, mentre "@", "/", "\" diverse conformazioni isomeriche [ATLO24].



Nonostante la sua ampia diffusione, **SMILES** presenta criticità strutturali che




Figure 3.1: Rappresentazione SMILES e struttura molecolare del Climbazolo.

ne limitano l'efficacia e lo rendono inadeguato agli strumenti computazionali moderni:

- Un primo limite della rappresentazione risiede nella **mancanza di univocità** che rende possibile la descrizione di una stessa molecola da molteplici stringhe diverse [LPP⁺24].
- Inoltre, il sistema SMILES è soggetto a una notevole fragilità sintattica che può portare facilmente all'invalidazione delle stringe a causa di piccole mutazioni di caratteri singoli (come una parentesi non chiusa), che rendono il complesso privo di significato biologico. Tale vulnerabilità risulta particolarmente problematica nell'uso di **Language Model** e modelli generativi, i quali producono combinazioni casuali di simboli durante la campionatura dello spazio latente.
- Infine, la natura lineare delle stringhe non permette di raffigurare correttamente la conformazione tridimensionale della molecola e le sue complesse relazioni spaziali [UAL23].

3.2.2 SELFIES

Le stringhe **SELFIES** (SELF-referencing Embedded Strings) sono state progettate con lo scopo di superare i limiti di SMILES, garantendo una robustezza del 100% [KAB⁺22] ed eliminando gli errori sintattici derivati dalle variazioni di caratteri. Ogni stringa SELFIES valida corrisponde a una molecola valida, poiché la

notazione si basa su una mappatura che impedisce violazioni dei vincoli fisici e strutturali. A differenza di SMILES, che è una notazione descrittiva, SELFIES è più simile a una libreria di stati finiti, i quali compongono una grammatica formale, un **automa** [LPP⁺24].

I SELFIES sono racchiusi tra parentesi quadre e definiscono, tramite identificatori locali, le ramificazioni e gli anelli in un unico punto, specificandone la lunghezza tramite *overloading*:

Quando il modello incontra un token di ramificazione o di anello, i numeri immediatamente successivi vengono interpretati come dimensione della sottostruttura di riferimento [LPP⁺24]. In questo modo vengono evitati con successo variazioni indesiderate causate da riferimenti con indici lontani tra loro nella stringa.

Questa proprietà rende i SELFIES particolarmente adatti per l'impiego in modelli generativi, poiché l'intero spazio latente esplorato da questi sarebbe composto da strutture chimicamente valide, che non richiederebbero ulteriori filtri o controlli. In modelli come i **Variational Autoencoders** (VAE), ciò permette di usare un'ottimizzazione basata sulla **discesa del gradiente continua** per ottimizzare le proprietà molecolari con un dominio di dati validi e chimicamente sensati.[KAB⁺22].



Figure 3.2: Confronto tra le notazioni per il benzene: SMILES (sopra) e SELFIES (sotto) [KAB⁺22].

Nonostante i vantaggi tecnici offerti dalle stringhe SELFIES in termini di robustezza, il sistema **SMILES** rimane comunque lo standard cheminformatico più popolare per diverse ragioni; in particolare la sintassi SELFIES e il suo meccanismo di overloading dei token risulta più difficile da interpretare visivamente e meno intuitivo per gli operatori umani [LPP⁺24]. Inoltre, sorprendentemente, in alcuni task di classificazione, modelli basati su SMILES hanno mostrato di superare le controparti basate su SELFIES. Questo comportamento può essere dovuto al fatto che lo SMILES, essendo più sensibile alla tokenizzazione (generano sequenze di token più brevi ed efficienti per la stessa molecola), permette di catturare pattern unici, talvolta trascurati dai modelli SELFIES, che tendono invece a generalizzare

eccessivamente le caratteristiche molecolari. Inoltre, questa maggiore compattezza permette ai **Transformer** di allocare la matrice di **attention** in modo più efficace, concentrandosi su un numero minore di unità informative [LPP⁺24].

3.3 Fingerprint molecolari

I *fingerprint* dall'altro canto adottano un approccio vettoriale: La molecola viene decomposta in frammenti locali che vengono poi convertiti, tramite funzioni di hashing, in un formato *machine-readable*, ovvero in un vettore numerico di lunghezza fissa. Questi vettori codificano caratteristiche specifiche, come la presenza o l'assenza di determinate strutture (*binary fingerprints*) o il numero di occorrenze di determinati pattern molecolari (*count-based fingerprints*), permettendo agli algoritmi di ML di analizzare le molecole per task di *Virtual Screening* e previsione di proprietà biologiche [BBC⁺24].

Esistono diverse categorie principali di fingerprint, suddivise in base al tipo di informazione che catturano [BBC⁺24]:

- Fingerprints "**String-based**": Operano direttamente sulla stringa SMILES, frammentando la stringa in sottosequenze di dimensione fissa e calcolando il numero di occorrenze di questi frammenti.
- Fingerprints "**Path-based**": Data una rappresentazione **a grafo** della molecola (che verrà approfondita nella prossima sezione), vengono analizzati i **cammini lineari**, utilizzando, ad esempio, algoritmi come il **DFS (Depth First Search)**, che percorrono la molecola partendo da ogni singolo atomo fino ad una distanza di d legami, mantenendo un record di ogni percorso unico.
- Fingerprints **Farmacoforici**: Si focalizzano sulla reattività chimica piuttosto che sulla struttura scheletrica. I farmacofori sono l'insieme di caratteristiche chiave di una molecola all'interno del suo ambiente biochimico, come i punti di interazione, donatori/accettori, legami a idrogeno, gruppi idrofobici, ecc... Questi fingerprints codificano il modo in cui la molecola interagisce con l'ambiente circostante, concentrandosi maggiormente sulle proprietà funzionali, piuttosto che sulla struttura anatomica esatta.

- Fingerprints ”**Substructure-based**”: Basati sulla presenza di sottostrutture chimiche predefinite. Questo tipo di fingerprints utilizza un ”dizionario” di frammenti noti, precedentemente individuati da esperti.
- Fingerprints **Circolari**: Partendo da un atomo, l’algoritmo di fingerprint aggrega le informazioni degli atomi vicini tra loro entro un raggio crescente, di fatto scomponendo la molecola in frammenti sullo stesso arco. Si tratta della tecnica più utilizzata per i modelli di Machine Learning, poiché è in grado di catturare informazioni sull’ambiente locale dell’atomo in modo strutturato ed esaustivo.

3.3.1 Esempi di fingerprints

Alcuni esempi appartenenti alla categoria di rappresentazione con **fingerprint molecolari** sono le **Morgan fingerprints** (o *Extended Connectivity Fingerprints* (ECFP)) e le **MACCS key**.

Le prime si distinguono come strumento fondamentale e standard *de facto* per la codifica dei composti farmaceutici *drug-like*.

Queste fingerprints **circolari** sono in grado di costruire dinamicamente i frammenti delle sottostrutture molecolari, a partire dalla loro rappresentazione a grafo [BBC⁺24].

Per prima cosa, gli atomi del composto vengono identificati in base alle loro proprietà chimiche con un numero identificativo univoco. Successivamente avviene l’aggregazione a raggio crescente (descritta precedentemente) e infine l’*hashing*, che trasforma la sequenza di identificatori in un vettore di tipicamente **1024 bit**.

Le **MACCS key (Molecular Access System)**, invece, si basano su un approccio più storico e utilizzano, come suggerito dal nome, un **dizionario** statico predefinito di sottostrutture, da cui attingere per codificare le strutture: Sono rappresentate da un vettore binario da **166** bit di lunghezza. Ognuno di questi bit codifica la assenza/presenza (0,1) di una specifica caratteristica strutturale, definita tramite i pattern **SMARTS** (SMILES Arbitrary Target Specification) [BBC⁺24] [UAL23] che identificano, all’interno del dizionario, frammenti, gruppi funzionali o motivi molecolari.




Figure 3.3: Struttura chimica dell'Ibuprofene.

Indici dei bit attivi rilevati: [74, 115, 123, 139, 141, 149, 154, 155, 157, 159, 160, 162, 163, 164, 165]

Le stringhe SMILES vengono quindi utilizzate per costruire la sintassi dei fingerprint MACCS key, rendendo la rappresentazione della molecola più estesa e arricchita, e con maggiori dettagli sulla struttura.

Listing 3.1: Estrazione delle MACCS Keys tramite RDKit

```
1 from rdkit import Chem
2 from rdkit.Chem import MACCSkeys
3
4 smiles = "CC(C)Cc1ccc(cc1)C(C)C(=O)O"
5 mol = Chem.MolFromSmiles(smiles)
6 maccs_key = MACCSkeys.GenMACCSKeys(mol)
7 bit_string = maccs_key.ToBitString()
8
9 maccs_166 = [int(b) for b in bit_string][1:]
```

Nonostante i fingerprint molecolari offrano diversi vantaggi significativi rispetto alle rappresentazioni lineari, specialmente in termini di efficienza computazionale e interpretabilità, questi presentano una perdita di informazioni non trascurabile durante il loro processo di codifica *hashing*, soprattutto per quanto riguarda i dati sulla connettività dei frammenti [UAL23]. È quindi necessario risalire a una **ricostruzione lossless** (senza perdita di informazioni), invertendo la traduzione dei fingerprint. Si tratta di un processo computazionale basato sull'architettura **Transformer**, che viene utilizzata come un sistema di traduzione in grado di apprendere le dipendenze globali tra input (i bit del fingerprint) e output (token di stringhe molecolari molecolari), grazie al meccanismo di *multi-head attention*. Il modello riesce quindi a decodificare i fingerprint strutturali riconducendoli a rappresentazioni lineari univoche (SMILES o SELFIES) [UAL23].

Vettore MACCS Key (Primi 100 bit in matrice 10x10)

0	0	0	0	0	0	0	0	0	0
10	0	0	0	0	0	0	0	0	0
20	0	0	0	0	0	0	0	0	0
30	0	0	0	0	0	0	0	0	0
40	0	0	0	0	0	0	0	0	0
50	0	0	0	0	0	0	0	0	0
60	0	0	0	0	0	0	0	0	0
70	0	0	0	1	0	0	0	0	0
80	0	0	0	0	0	0	0	0	0
90	0	0	0	0	0	0	0	0	0
	+0	+1	+2	+3	+4	+5	+6	+7	+8

Figure 3.4: Primi 100 bit del fingerprint dell'Ibuprofene

3.4 Rappresentazione a grafo

La rappresentazione a **grafo** costituisce l'approccio più intuitivo e fedele alla realtà fisica per la digitalizzazione delle strutture chimiche, superando i limiti informativi delle notazioni lineari e minimizzando la perdita di dati.

La molecola viene rappresentata come un grafo non orientato $G = (V, E)$ [WLB23], in cui:

Nodi (V): Rappresentano gli atomi della molecola.

Archi (E): Rappresentano i legami chimici interatomici.

Tale struttura permette di codificare direttamente la topologia (informazioni bidimensionali, come i legami covalenti) e la connettività della molecola (la geometria, le informazioni tridimensionali), trasformando le proprietà del composto in **matrici** elaborabili da modelli di Intelligenza Artificiale.

Per essere interpretata dai computer, la struttura del grafo viene convertita in matrici, convertendo così la informazioni chimiche in un linguaggio matematico adatto ad essere appreso dai modelli [WZ25].




Figure 3.5: Rappresentazione topologica non orientata $G = (V, E)$ dell'Ibuprofene generata da codice grazie a librerie RDKit e NetworkX.

Questa rappresentazione è il pilastro fondamentale per le **GNN (Graph Neural Networks)**, argomento che verrà affrontato nel prossimo capitolo.

3.5 Embedding molecolari e modelli pre-addestrati

L'**embedding molecolare** è un'operazione fondamentale nella ricerca farmaceutica. Questo processo consiste nel trasformare le informazioni relative al contesto strutturale e chimico di una molecola in una **rappresentazione numerica**, tipicamente sotto forma di vettori densi ad alta dimensione.

Questa pratica si basa su un'ipotesi di base: **tutte le molecole strutturalmente simili, presentano comportamenti e proprietà altrettanto simili**. Seguendo questa ipotesi, l'embedding cerca di mappare queste molecole in punti vicini nello spazio vettoriale [SBF⁺24].

I vettori di embedding possono essere generati principalmente in due modi distinti:

- **Embedding basati su Grafi** (come ad esempio i **GNN**). Gli embedding

vengono estratti dalla struttura a grafo tramite le fasi di *update* dei nodi-atomo e di *message passing* [WKL⁺23]. In particolare, per ogni atomo u , viene calcolato l'embedding $h_u^{(t+1)}$ (con t che rappresenta il livello corrente del *message passing*) aggregando i messaggi dai nodi vicini v . Durante il passaggio dei messaggi vengono inoltre integrate le caratteristiche dei legami chimici rappresentati dagli archi della GNN, x_{uv} . Durante la fase di *readout*, gli embedding di tutti i nodi vengono aggregati:

$$\hat{y} = R(\{h_u^{(L)} | u \in \mathcal{V}\})$$

Il risultato è un vettore riassuntivo degli embedding molto ricchi calcolati nei vari livelli della rete, che sarà usato per compiere predizione sulla molecola nel suo complesso, integrando le informazioni sulle sottostrutture e la sua topologia.

- **Embedding basati su stringhe (LLM).** Sfruttano le rappresentazioni lineari testuali come **SMILES** per effettuare la codifica in vettori, catturando le informazioni semantiche e contestuali [SBF⁺24]. Questo processo avviene tramite tokenizzazione delle stringhe SMILES da parte di **Large Language Models** (che sono in grado di processarle in quanto dati in formato testuale), che vengono quindi elaborati dall'architettura a **Transformer**.

Per verificare la qualità dell'embedding estratto si utilizzano i **modelli di probe**, ovvero semplici classificatori lineari addestrati su vettori fissi, che sono in grado di verificare le informazioni catturate.

Un embedding di alta qualità dovrebbe essere in grado di rappresentare correttamente **proprietà topologiche**, **proprietà nello spazio** e **sottostrutture molecolari**.

Chapter 4

DTI e DTA

4.1 Target Prediction

L'identificazione di un bersaglio biologico rappresenta una delle sfide iniziali della pipeline di sviluppo di un farmaco. L'oggetto di questa ricerca è una molecola *target* che dimostra una particolare importanza nel contesto di una patologia, e di cui l'attività può essere "attaccata" o "drogata" da un farmaco, per ottenere un effetto terapeutico.

Storicamente, l'identificazione dei target si è basata su un processo sperimentale di *trial and error* e intuizione scientifica (basata quindi sulle conoscenze dei ricercatori). Tra gli approcci tradizionali più comunemente utilizzati si distinguono:

- L'**Affinity Pull-down** usato per isolare le proteine bersaglio tramite affinità specifica ad altre molecole "di prova" [ZYW⁺25].
- Lo **screening knockdown** dell'intero genoma, volto a identificare il ruolo dei target tramite disattivazione genica [ZYW⁺25].
- L'**High-Throughput Screening (HTS)**, screening ad alta velocità per l'analisi massiva di interazioni molecolari automatizzate [MBD⁺26].
- **Metodi sperimentali** ad alta precisione, come la **cristallografia a raggi X** o la **spettroscopia NMR**, che vengono tutt'ora impiegate per descrivere le interazioni ligando-proteine su scale più ridotte [KS26].

Tuttavia, questi approcci presentavano ostacoli significativi, che rendevano lo sviluppo di nuovi farmaci particolarmente dispendioso e inefficiente, con un *attrition rate* medio del 90% [Fre]. Le cause principali di queste criticità sono spesso riconducibili a **bias soggettivi** dei ricercatori, che possono restringere eccessivamente lo spettro della *discovery* ed escludendo dal processo composti adeguati ma sconosciuti. Inoltre, la limitata scalabilità di questo tipo di approcci sperimentali impedisce la copertura dell'enorme spazio biochimico di candidati possibili (composto da tutte le combinazioni farmaco-target).

Rimane, oltre ai problemi riguardanti l'efficacia dei legami con il bersaglio, la questione della **druggability**. Oltre il 90% delle proteine umane è ancora poco conosciuto dal punto di vista strutturale [Fre] oppure è privo di opportuni *binding points* (o punti di legame) per l'agganciamento stabile di piccole molecole. Questi target vengono definiti "Undruggable".

Oggi l'**Intelligenza Artificiale** sta rivoluzionando questo campo, permettendo l'analisi sistematica di volumi enormi di dati biologici provenienti da fonti diverse, basandosi sul riconoscimento di schemi e pattern ricorrenti tra diverse patologie.

4.2 Drug Target Interaction (DTI)

La fase di *target prediction* può essere facilmente ricondotta al problema computazionale della **Drug-Target Interaction (DTI)**. Questo consiste nel prevedere attraverso modelli matematici e algoritmi, se, e con quale intensità, una determinata molecola interagirà con un target specifico.

Il nucleo di questo problema computazionale risiede nella capacità di modellare correttamente la **funzione di interazione** (o funzione di **scoring**), il cui ruolo principale è lo stimare l'energia libera di legame (ovvero l'affinità di legame) prevista tra farmaco e proteina-bersaglio [MBD⁺26].

$$f(d, t) \rightarrow y$$

In questo contesto, l'algoritmo ha il compito di filtrare lo spazio chimico. Data una proteina t (*target*), il modello esplora un dataset massivo di sequenze molecolari

$\{d_1, d_2, \dots, d_n\}$ per identificare quelle che massimizzano la **funzione di scoring**. Questi valori calcolati permettono di creare un *ranking* dei potenziali composti candidati e delle interazioni più potenzialmente efficaci.

Questo processo è il passaggio cruciale della ricerca farmacologica moderna da problema sperimentale biochimico a problema di **ottimizzazione** e ricerca in uno **spazio latente** a dimensionalità alta.

La funzione può determinare, in base alla sua tipologia di output, due approcci principali:

- **Classificazione Binaria** $\{0,1\}$, se il modello fornisce un output booleano, che indica la assenza/presenza di interazione con il target [MBD⁺26].
- **Regressione**, se il modello ritorna un valore continuo che quantifica la forza di legame, ovvero la **Drug-Target Affinity (DTA)**. Questa stima si pone come obiettivo la previsione di parametri biologici come la **costante di dissociazione** (K_d), la **costante di inibizione** (K_i) o la **concentrazione inibente** (IC_{50}). Una volta calcolati, questi valori vengono convertiti in scala logaritmica per stabilizzare la convergenza durante la fase di *training* dei modelli di Deep Learning [KS26].

Sia D lo spazio chimico dei farmaci, e T lo spazio biologico dei target, l'insieme delle relazioni tra i due può essere formalizzato attraverso una **matrice di interazione** farmaco-bersaglio (DTI matrix) [MBD⁺26], in cui le righe rappresentano i ligandi, mentre le colonne rappresentano i bersagli biologici. Di conseguenza, ogni cella $M_{i,j}$ contiene il valore dell'interazione tra il farmaco i -esimo e il target j -esimo (in formato binario per la DTI e come valore continuo nella DTA).

Questo tipo di rappresentazione presenta tuttavia una problematica strutturale: le matrici di interazione sono infatti estremamente **sparse**, a causa del fatto che la maggiorparte delle coppie d - t non sono mai state testate sperimentalmente e non si hanno quindi informazioni a riguardo. Per superare tale limite, si ricorre a tecniche di *Matrix Factorization* avanzate, come la *Neighbourhood Regularized Logistic Matrix Factorization (NRLMF)*, che decompongono la matrice in componenti latenti per identificare pattern nascosti e prevedere interazioni sconosciute [MBD⁺26].

Tuttavia, questo approccio tratta la matrice come un oggetto isolato e non sfrutta le relazioni strutturali tra i composti stessi, come la **similarità** chimica o funzionale tra molecole. Per integrare questo tipo di informazioni, le DTI matrix vendono reinterpretate come le matrici di adiacenza di una **DTI Network**:

Si tratta di un **modello di rete bipartita eterogenea**, in cui i nodi di una partizione (composti) sono collegati ai nodi dell'altra (target) tramite archi che rappresentano le interazioni note tra i due. Questa riformulazione supera la staticità della matrice "piatta" e permette di modellare le relazioni intra-partizione, oltre a quelle farmaco-target, arricchendo ulteriormente il quadro informativo per la predizione [MBD⁺26].

Modelli di ML supervisionato come il *Bipartite Local Model* (BLM) sfruttano questa struttura per costruire dei classificatori *locali* specifici per ogni nodo della rete. A differenza di modelli globali che analizzano la rete nella sua interità, il BLM addestra un classificatore separato per ogni farmaco e ogni target, rifacendosi alle interazioni nel *neighbourhood* del nodo come segnale supervisionato. Questa strategia permette di catturare pattern specifici dei protagonisti dell'interazione, che i modelli globali generalizzerebbero eccessivamente.

4.2.1 Rappresentazione degli input

4.3 Metodologie di Predizione

L'obiettivo è la costruzione di un modello che, in seguito ad un addestramento, sia in grado di fare generalizzazioni su coppie farmaco-target mai osservate prima, stimando correttamente la probabilità di interazione e la sua intensità.

Queste metodologie si differenziano in base al tipo di informazione su cui si basano:

- I metodi **ligand-based**, tra cui rientrano i modelli **QSAR** (*Quantitative Structure-Activity Relationship*), che associano le proprietà strutturali di un determinato composto con la sua attività biologica. Storicamente implementati tramite modelli lineari, i modelli QSAR si sono nel tempo evoluti verso modelli di ML e DL di complessità ed efficienza maggiore, rimanendo comunque di natura *ligand-based*. Anche la **modellazione farmacoforica**

fa parte di questa categoria, e serve ad identificare le caratteristiche strutturali minime di un composto per ottenere l'interazione desiderata con il bersaglio, stringendo il cerchio di possibili candidati (risulta particolarmente utile nei casi in cui la struttura 3D della proteina non è ricavabile [MBD⁺26]).

- I metodi **structure-based** che, al contrario dei precedenti, richiedono la conoscenza della struttura 3D della proteina target, al fine di simulare l'interazione chimica. Il rappresentante principale di questa categoria è il **docking molecolare**, che verrà trattato nella sezione successiva.
- I metodi **network-based**, comprendono la DTI network e il modello BLM, già citati in precedenza. Questi rappresentano i farmaci e i target attraverso i nodi di un grafo e sfruttano la topologia della rete per analizzare nuove connessioni/interazioni.
- I metodi basati **Machine Learning** e **Deep Learning**, infine, rappresentano lo stato dell'arte. I modelli di ML classico apprendono pattern complessi a partire da descrittori progettati manualmente, mentre le architetture di DL estraggono automaticamente le informazioni facendo affidamento solo al dataset di input, senza richiedere *feature engineering*. Entrambi verranno trattati in dettaglio più avanti.

4.3.1 Docking Molecolare

4.3.2 Machine Learning (ML) e Deep Learning (DL)

Le metodologie computazionali per la predizione di interazioni farmaco-target hanno seguito un processo evolutivo motivato dalle limitazioni riportate dalle generazioni precedenti. I primi approcci si basavano su descrittori delle proprietà molecolari dei composti progettati manualmente e basati unicamente sulle competenze e conoscenze scientifiche degli esperti di laboratorio. Il subentro del **Deep Learning** ha risolto questa situazione di alta complessità e alto rischio di errore affrontando i problemi di DTI e DTA come un **task di apprendimento supervisionato**: Come menzionato in precedenza, il modello apprende la seguente

funzione

$$f(d, t) \rightarrow y$$

in grado di generalizzare su coppie drug-target non osservate, riconoscendo pattern chimici e biologici di alta complessità.

Questa sezione si propone di analizzare i modelli di ML e DL più utilizzati in questa fase della *drug discovery* e di seguirne l'evoluzione fino allo stato dell'arte.

Algoritmi di Machine Learning Classici

I modelli di ML tradizionale si basano spesso sulla *feature engineering* manuale, eseguita prima dell'addestramento del modello da ricercatori incaricati di selezionare le caratteristiche descrittive delle molecole, ovvero le loro proprietà fisico-chimiche. Tra questi modelli abbiamo i **Modelli Lineari** [ONCE24]:

- **MLR (Multiple Linear Regression)**
- La regressione dei **minimi quadrati parziali (PLS)**
- La **Regressione Lineare Bayesiana (RLB)**

Questi rappresentano tecniche statistiche in grado di generare una funzione lineare che descrive il legame tra i descrittori molecolari (le variabili x , dette "indipendenti") e l'esito della predizione, ovvero l'affinità di legame (variabili y , "dipendenti") [ONCE24]. In questo modo, il modello è capace di calcolare come i cambiamenti nelle proprietà dei composti influenzino l'attività biologica di essi. Diventa quindi possibile prevedere il comportamento di nuovi composti da analizzare, semplicemente "consultando" la linea di regressione e inserendo i nuovi parametri nella funzione.

Il limite di questi modelli, tuttavia, risiede proprio nella loro possibilità di catturare unicamente relazioni lineari, escludendo quindi pattern di interazione più complessi.

Per superare questo ostacolo di complessità subentrano metodi più avanzati, come **Random Forest** e gli **alberi di decisione (DT)**, che sono in grado di ricavare dai dati relazioni complesse, rappresentabili da funzioni non-lineari.

I **DT** sono una struttura dati ad albero in cui i dati vengono ricorsivamente partizionati in sottoinsiemi in base a caratteristiche specifiche come, in questo caso, particolari proprietà molecolari. In questo modo i rami della struttura rappresentano i possibili esiti del problema di classificazione/regressione (in base al tipo di task che viene affrontato, DTI o DTA). Una volta "riempito", il DT può essere usato come modello predittivo, in grado di classificare nuovi composti in base al loro percorso guidato dalla radice fino alle foglie dell'albero [ONCE24]. Queste tecniche sono efficaci e facili da interpretare, ma soffrono di **overfitting**: infatti, questi modelli tendono a "memorizzare" le caratteristiche dei dati del *training set*, senza realmente apprendere dei pattern per generalizzare il comportamento dei vari input. In questo modo, le prestazioni risultano eccellenti durante la fase di training ma abbastanza scarse durante la fase di test o l'identificazione di nuovi dati.

La **Random Forest (RF)** è una tecnica di *ensemble learning* progettata per ridurre il fenomeno di overfitting. È composta da più DT combinati e addestrati su sottoinsiemi differenti del dataset generale. La decisione finale avviene tramite voto di maggioranza, nel caso della DTI, o tramite media, nel caso della DTA.

Oltre agli algoritmi *tree-based*, sono utilizzate anche tecniche come **Support Vector Machines (SVM)**. Queste affrontano la classificazione DTI cercando, all'interno dello spazio dei descrittori, l'**iperpiano di separazione** con margine massimo tra coppie in interazione e non interagenti. L'iperpiano ottimale è quello che massimizza la distanza tra i punti più vicini di ciascuna delle due classi, infatti più il margine è ampio e migliore sarà la capacità del modello di fare previsioni su coppie mai osservate. Questi punti "di confine" vengono chiamati **vettori di supporto** e garantiscono la funzionalità del sistema [MLMLC22].

Per gestire la non-linearità delle proprietà biologiche, SVM ricorre al **kernel trick**, che "solleva" i dati di una dimensione, garantendo sempre la separazione lineare. Il kernel non necessita delle coordinate dei punti nello spazio, ma ricava direttamente il loro **prodotto scalare** calcolandolo in uno spazio a dimensionalità superiore [MLMLC22].

Il limite strutturale comune a tutti gli approcci di ML tradizionale è la dipendenza della predizione dalla qualità dei descrittori selezionati [AOH26]. L'inadeguatezza delle proprietà molecolari in esame può compromettere il lavoro del modello in-

dipendentemente dalla sua potenza di calcolo o dalla sua efficienza. Questo vincolo è proprio la motivazione del passaggio verso le architetture di **Deep Learning**, in grado di apprendere in modo autonomo le informazioni dai dataset.

Algoritmi di Deep Learning

Invece di ricevere parametri calcolari manualmente, questi modelli ricavano le caratteristiche più informative direttamente dai dati "grezzi", siano questi stringhe SMILES, sequenze amminoacidiche o grafi molecolari [WLX⁺26].

Modelli basati su sequenze I modelli *sequence-based* affrontano il problema DTI trattando direttamente le stringhe SMILES o i fingerprint del farmaco e le sequenze delle proteine come dati testuali unidimensionali, senza richiedere input formalizzati "su misura" [TZYL24].

Le **CNN** o **Reti Neurali Convoluzionali** rappresentano una delle prime architetture DL applicate con successo a questo tipo di input biologico. Nascono principalmente per processare dati in formato a griglia come i pixel nelle immagini, ma possono essere adottate in ambito di predizione DTI e DTA per lavorare su task di QSAR, tramite **convoluzione unidimensionale**[ONCE24]. Il processo si divide in tre fasi principali che seguono i diversi strati della rete:

- **Layers Convoluzionali**, che scansionano le sequenze dei composti e ricercano al loro interno dei pattern strutturali locali, detti *motif*. Il risultato del passaggio attraverso questi strati è la composizione di una matrice **feature map**, che indica le feature estratte e il grado di certezza nella loro rilevazione.
- **Layers di Pooling**, che riducono la dimensionalità delle feature map ottenute, riassumendo solo le informazioni più importanti e utili per la previsione di nuovi composti. Questo step, oltre a rendere il modello più leggero, è fondamentale per la riduzione del *noise*, ovvero informazioni superflue che potrebbero compromettere il risultato del procedimento con piccole variazioni di misurazione e impurità nei dati.
- **Layers Fully Connected**, infine, sono strati densi che combinano tra loro

le caratteristiche apprese dalle mappature nei livelli precedenti, per generare una previsione finale.

Questo tipo di reti neurali sono facilmente scalabili e molto efficienti ma, facendo uso di informazioni 1D, fanno anch'esse fatica ad incorporare strutture tridimensionali più complesse e a catturare le dipendenze biochimiche tra elementi [HLY⁺25].

Le **RNN (Recurrent Neural Networks)** sono un'altra architettura di Deep Learning progettata per l'elaborazione di dati sequenziali. A differenza delle CNN, però, queste reti non sono in grado di modellare in modo corretto e affidabile le dipendenze tra atomi tra loro distanti [WLX⁺26].

Operano mantenendo un **layer nascosto**, che si evolve con l'elaborazione della sequenza di input. Nel contesto della predizione di interazioni con il target farmacologico, le RNN, come le CNN, analizzano efficacemente le stringhe SMILES dei composti per apprendere i **motifs** strutturali e i pattern nelle relazioni che determinano l'affinità di legame.

Modelli basati sui grafi I modelli *sequence-based*, anche se risultano più semplici nella formattazione degli input e più facilmente scalabili, faticano a prendere conoscenza del contesto tridimensionale del sito di legame [WLX⁺26]. Questa perdita di informazioni può essere superata grazie alla rappresentazione a grafo tipica dei modelli trattati in questa sezione.

Come accennato nel capitolo precedente, questo tipo di rappresentazione permette l'elaborazione dei contesti da parte delle **GNN (Graph Neural Networks)**, che operano simulando la topologia e le relazioni spaziali reali dei composti chimici (legami tra atomi *intra* e *inter* composto) propagando informazioni tra i nodi tramite il meccanismo di *message passing*.

4.3.3 GNN per molecole

Le **Graph Neural Networks** sono modelli di deep learning progettati per operare direttamente sulla struttura dei grafi. Il meccanismo centrale che permette ai nodi

di raccogliere le informazioni dai propri vicini è il **Message passing**. Questo processo avviene in due passaggi iterativi [WLBF23]:

- **Computazione e Aggregazione:** Il modello calcola un messaggio elaborando le caratteristiche del nodo centrale, con quelle dei nodi e degli archi ad esso adiacenti.
- **Aggiornamento:** Lo stato del nodo viene aggiornato integrando il nuovo messaggio con la sua informazione precedente.

Queste informazioni elaborate vengono poi lette tramite l'operazione di **Read-out**. Attraverso un meccanismo simile al pooling, le caratteristiche di tutti i nodi vengono aggregate e aggiornate in un unico vettore di caratteristiche globali, in grado di rappresentare lo stato dell'intera molecola [WLBF23].

In generale, nel contesto di drug discovery le GNN stanno rivoluzionando il concetto di tradizionale **Computer-Aided Drug Design** (CADD), trasformando il processo in una ricerca automatizzata. Queste architetture consentono di esplorare lo spazio chimico per generare e ottimizzare (come nella *Lead Optimization*) nuove entità molecolari, apportando migliorie nelle proprietà desiderate, come bioattività, stabilità e sintetizzabilità. Le GNN risultano, inoltre, fondamentali nello screening virtuale per prevedere con efficienza le affinità di legame tra farmaci e target. Questo permette uno studio precoce di proprietà ADMET e della tossicità, portando a una riduzione drastica di fallimenti nei test clinici [WZ25].

Nel contesto di DTA/DTI...

Transorfmer e modelli linguistici

Chapter 5

ADMET

La valutazione delle proprietà **ADMET** (Assorbimento, Distribuzione, Metabolismo, Escrezione e Tossicità) è considerata un passaggio critico all'interno della pipeline di sviluppo farmacologico, al fine di ridurre "a monte" i tassi di fallimento nelle fasi cliniche. Infatti, la scorretta valutazione di queste proprietà rappresenta un incremento nel rischio di logoramento dei farmaci candidati.

5.1 Il framework ADMET

L'impiego del Machine Learning in questo campo rappresenta un'importante svolta metodologica rispetto ai test empirici tradizionali [?], poiché permette di processare grandi volumi di dati molecolari per prevederne il comportamento farmacocinetico con costi e tempi drasticamente ridotti, allargando il primo "collo di bottiglia" del processo di ricerca.

In questo nuovo contesto, il framework ADMET non viene più interpretato come una serie di test isolati, ma come un sistema integrato di vincoli biochimici che si influenzano a vicenda e che determinano la sicurezza di una molecola.

5.2 La tossicità molecolare

TO-DO

5.3 Evoluzione verso il Machine Learning per la predizione ADMET

Storicamente, i primi tentativi di razionalizzare le proprietà e l'attività biologica delle molecole si basava su metodi come *quantitative structure-activity relationship* (QSAR) e *structure-activity relationship* (SAR). Tuttavia questi metodi presentavano un limite fondamentale: la necessità di una selezione manuale e di un'accurata rappresentazione delle *feature* chimiche. Con l'avvento del ML classico, tuttavia, l'attenzione si è spostata verso l'uso di rappresentazioni come i *chemical fingerprints*, che vengono presi come input da algoritmi come **Random Forest**, **Support Vector Machines**, **k-Nearest Neighbors** e **XGBoost**. Questi ultimi hanno permesso di apprendere classificazioni complesse, trattando la molecola come un vettore binario che indica presenza/assenza di frammenti chimici, e raggiungendo risultati in modo veloce e con processi parzialmente interpretabili. Tuttavia, questi algoritmi ignorano la struttura tridimensionale e la connettività delle molecole, e le leggono invece come una sequenza di caratteristiche booleane, rendendo le interazioni tra frammenti vicini nello spazio ma lontani nella stringa di difficile predizione.

Per una predizione più accurata di queste interazioni più complesse, **Li et al. (2026)** propongono un modello chiamato **CMA**, ovvero "Cross-Aligned Multimodal Attention". L'idea centrale è proprio quella di rappresentare la molecola come in un **attention cross-modale**, ovvero tramite tre le matrici Query (Q), Key (K) e Value (V) del meccanismo di attention dei Transformer. Ogni matrice viene mappata a partire da una rappresentazione diversa, e solo una di queste fa riferimento ai *fingerprints*:

- Query utilizza **GROVER**, un algoritmo che decodifica informazioni sulla struttura delle molecole in un grafo in cui ogni nodo rappresenta un atomo e i legami chimici sono astratti come archi. GROVER è un **GNN** (Graph Neural Networks) preaddestrato su 10 milioni di molecole e permette la rappresentazione più ricca strutturalmente. Contribuisce a circa il 36% della contribuzione media finale.
- Value viene processata da **ResNet-50**, una CNN in grado di estrarre im-

magini molecolari bidimensionali e catturare così la forma, la simmetria e l'arrangiamento degli atomi dei soggetti candidati. La rete viene preaddestrata su 10 milioni di molecole. Contribuisce a circa il 22% della contribuzione media finale.

- Key, infine, fa uso di **fingerprint MACCS**, composta da 166 bit che codifica l'occorrenza di gruppi chimici specifici. Contribuisce a circa il 42% della contribuzione media finale.

La funzione di punteggio di Attention è definita come segue:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

La modalità Query "interroga" la modalità Key per determinare quali elementi siano più rilevanti all'interno del contesto corrente. Il risultato è infine un media pesata dalla modalità Value. Tradotto nell'ambito molecolare, la rappresentazione a grafo può interrogare le *fingerprint* per comprendere al meglio quali siano le caratteristiche strutturali locali più coerenti con la topologia generale, mentre il risultato finale viene modulato dalle immagini estratte da ResNet. [?]

5.4 Multimodalità e meccanismi di Attention

Chapter 6

State of the art

I suggest referencing stuff as follows: fig. 6.1 or Figure 6.1

6.1 Some cool topic




Figure 6.1: Some random image

Chapter 7

Contribution

You may also put some code snippet (which is NOT float by default), eg: chapter 7.

7.1 Fancy formulas here

```
1 public class HelloWorld {
2     public static void main(String[] args) {
3         // Prints "Hello, World" to the terminal window.
4         System.out.println("Hello, World");
5     }
6 }
```

Bibliography

- [AOH26] Bilal Ahmad, Khmaies Ouahada, and Habib Hamam. Machine learning for drug-target interaction prediction: A comprehensive review of models, challenges, and computational strategies. *Computational and Structural Biotechnology Journal*, 31:316–345, January 2026.
- [ATLO24] Nicholas Aksamit, Alain Tchagang, Yifeng Li, and Beatrice Ombuki-Berman. Hybrid fragment-SMILES tokenization for ADMET prediction in drug discovery. *BMC bioinformatics*, 25(1):255, August 2024.
- [BBC⁺24] Davide Boldini, Davide Ballabio, Viviana Consonni, Roberto Todeschini, Francesca Grisoni, and Stephan A. Sieber. Effectiveness of molecular fingerprints for exploring the chemical space of natural products. *Journal of Cheminformatics*, 16(1):35, March 2024.
- [BGF⁺22] Mariana Pegrucci Barcelos, Suzane Quintana Gomes, Leonardo Bruno Federico, Isaque Antonio Galindo Francischini, Lorane Izabel da Silva Hage-Melim, Guilherme Martins Silva, and Carlos Henrique Tomich de Paula da Silva. Lead Optimization in Drug Discovery. In Carlton A. Taft and Sergio R. de Lazaro, editors, *Research Topics in Bioactivity, Environment and Energy: Experimental and Theoretical Tools*, pages 481–500. Springer International Publishing, Cham, 2022.
- [CL24] Jens Carlsson and Andreas Lutten. Structure-based virtual screening of vast chemical space as a starting point for drug discovery. *Current Opinion in Structural Biology*, 87:102829, August 2024.

- [Fre] David H Freedman. Hunting for New Drugs with AI.
- [HLY⁺25] Jingjing Hou, Zixin Li, Mengjun Yang, Binjie Wang, Bing Wang, and Xiaohui Yang. DGCA-DTA: A Deep Graph Neural Network Based on Co-Attention for Drug Target Affinity Prediction. *IEEE Transactions on Computational Biology and Bioinformatics*, 22(5):2093–2104, September 2025.
- [JPS22] Kevin Maik Jablonka, Luc Patiny, and Berend Smit. Making the collective knowledge of chemistry open and machine actionable. *Nature Chemistry*, 14(4):365–376, April 2022.
- [KAB⁺22] Mario Krenn, Qianxiang Ai, Senja Barthel, Nessa Carson, Angelo Frei, Nathan C. Frey, Pascal Friederich, Théophile Gaudin, Alberto Alexander Gayle, Kevin Maik Jablonka, Rafael F. Lameiro, Dominik Lemm, Alston Lo, Seyed Mohamad Moosavi, José Manuel Nápoles-Duarte, AkshatKumar Nigam, Robert Pollice, Kohulan Rajan, Ulrich Schatzschneider, Philippe Schwaller, Marta Skreta, Berend Smit, Felix Strieth-Kalthoff, Chong Sun, Gary Tom, Guido Falk von Rudorff, Andrew Wang, Andrew D. White, Adamo Young, Rose Yu, and Alán Aspuru-Guzik. SELFIES and the future of molecular string representations. *Patterns*, 3(10), October 2022.
- [Ken24] Terry Kenakin. Know your molecule: Pharmacological characterization of drug candidates to enhance efficacy and reduce late-stage attrition. *Nature Reviews Drug Discovery*, 23(8):626–644, August 2024.
- [KG23] Monalisa Kesh and Sachin Goel. Target-Based Screening for Lead Discovery. In Mithun Rudrapal and Johra Khan, editors, *CADD and Informatics in Drug Discovery*, pages 141–173. Springer Nature, Singapore, 2023.
- [KS26] Sheo Kumar and Amritpal Singh. Predicting drug-target interactions and binding affinity using an optimized deep learning approach. *Journal of Computer-Aided Molecular Design*, 40(1):84, March 2026.

- [LPP⁺24] Miguelangel Leon, Yuriy Perezhohin, Fernando Peres, Aleš Popovič, and Mauro Castelli. Comparing SMILES and SELFIES tokenization for enhanced chemical language modeling. *Scientific Reports*, 14(1):25016, October 2024.
- [MBD⁺26] Hiranmoy Mondal, Amlan Bishal, Biplab Debnath, Aakriti Patel, Joy Das, and Tahreen Taj. AI-driven drug–target interaction prediction: Current progress, challenges, and future roadmap for precision medicine. *Journal of Computer-Aided Molecular Design*, 40(1):89, March 2026.
- [McI07] Campbell McInnes. Virtual screening strategies in drug discovery. *Current Opinion in Chemical Biology*, 11(5):494–502, October 2007.
- [MLMLC22] Osva Antonio Montesinos López, Abelardo Montesinos López, and Jose Crossa. Support Vector Machines and Support Vector Regression. In Osva Antonio Montesinos López, Abelardo Montesinos López, and José Crossa, editors, *Multivariate Statistical Machine Learning Methods for Genomic Prediction*, pages 337–378. Springer International Publishing, Cham, 2022.
- [ONCE24] Adeshina I. Odugbemi, Clement Nyirenda, Alan Christoffels, and Samuel A. Egieyeh. Artificial intelligence in antidiabetic drug discovery: The advances in QSAR and the prediction of α -glucosidase inhibitors. *Computational and Structural Biotechnology Journal*, 23:2964–2977, July 2024.
- [RRS⁺22] Azhar Rasul, Ammara Riaz, Iqra Sarfraz, Samreen Gul Khan, Ghulam Hussain, Rabia Zara, Ayesha Sadiqa, Gul Bushra, Saba Riaz, Muhammad Javid Iqbal, Mudassir Hassan, and Khatereh Khorsandi. Target Identification Approaches in Drug Discovery. In Marcus T. Scotti and Carolina L. Bellera, editors, *Drug Target Selection and Validation*, pages 41–59. Springer International Publishing, Cham, 2022.

- [SBF⁺24] Shaghayegh Sadeghi, Alan Bui, Ali Forooghi, Jianguo Lu, and Alioune Ngom. Can large language models understand molecules? *BMC Bioinformatics*, 25(1):225, June 2024.
- [TZYL24] Xiwei Tang, Yiqiang Zhou, Mengyun Yang, and Wenjun Li. TC-DTA: Predicting Drug-Target Binding Affinity With Transformer and Convolutional Neural Networks. *IEEE Transactions on NanoBioscience*, 23(4):572–578, October 2024.
- [UAL23] Umit V. Ucak, Islambek Ashyrmamatov, and Juyong Lee. Reconstruction of lossless molecular representations from fingerprints. *Journal of Cheminformatics*, 15(1):26, February 2023.
- [WKL⁺23] Hanchen Wang, Jean Kaddour, Shengchao Liu, Jian Tang, Joan Lasenby, and Qi Liu. Evaluating Self-Supervised Learning for Molecular Graph Embeddings. *Advances in Neural Information Processing Systems*, 36:68028–68060, December 2023.
- [WLBF23] Yuyang Wang, Zijie Li, and Amir Barati Farimani. Graph Neural Networks for Molecules. In Chen Qu and Hanchao Liu, editors, *Machine Learning in Molecular Sciences*, pages 21–66. Springer International Publishing, Cham, 2023.
- [WLX⁺26] Yike Wang, Jingwei Lv, Yan Xia, Junlin Xu, Yajie Meng, Feifei Cui, Leyi Wei, Quan Zou, and Zilong Zhang. A unified survey on drug-target interaction and binding affinity prediction: Models, representations, and challenges. *Biotechnology Advances*, 88:108843, May 2026.
- [WZ25] Rui Wang and Chunlin Zhuang. Graph neural networks driven acceleration in drug discovery. *Acta Pharmaceutica Sinica B*, 15(12):6163–6177, December 2025.
- [ZYW⁺25] Kang Zhang, Xin Yang, Yifei Wang, Yunfang Yu, Niu Huang, Gen Li, Xiaokun Li, Joseph C. Wu, and Shengyong Yang. Artificial intelligence in drug development. *Nature Medicine*, 31(1):45–59, January 2025.

Acknowledgements

Optional. Max 1 page.