

Corso di Laurea in Ingegneria e Scienze Informatiche

Architetture di Machine Learning per la Predizione delle Interazioni Farmaco-Bersaglio e delle Proprietà ADMET

Tesi di laurea in:
MACHINE LEARNING AND DATA MINING

Relatore

Golfarelli Matteo

Candidato

Ventura Elettra

Correlatore

Montagna Sara

Abstract

Max 2000 characters, strict.

Optional. Max a few lines.

Contents

Abstract	iii
1 Introduction	1
2 Pipeline di sviluppo farmaceutico	3
2.1 Le fasi del Drug Development	3
2.1.1 Target Prediction	3
2.1.2 Dalla <i>target discovery</i> alla <i>hit generation</i>	5
2.1.3 Screening dei composti	6
2.2 Attrition Rate e impatto economico	8
2.3 Il ruolo dell'AI nella pipeline	8
3 Rappresentazione molecolare e machine readability	11
3.1 Lettura di dati chimici e biologici in informatica	11
3.2 Rappresentazioni lineari: SMILES e SELFIES	12
3.2.1 SMILES	12
3.2.2 SELFIES	14
3.3 Fingerprint molecolari	15
3.3.1 Esempi di fingerprints	17
3.4 Rappresentazione a grafo	19
3.5 Embedding molecolari e modelli pre-addestrati	20
3.6 Rappresentazione delle proteine target: FASTA	21
3.6.1 AlphaFold	22
4 DTI e DTA: Predizione delle interazioni Farmaco-Bersaglio	25
4.1 Il problema computazionale	25
4.1.1 DTI: classificazione binaria	26
4.1.2 DTA: regressione del livello di affinità	26
4.1.3 Matrice di interazione e DTI Network	26
4.2 Metodologie di Predizione	28
4.2.1 Metodi ligand-based e structure-based	29

CONTENTS

4.3	Machine Learning Classico	32
4.3.1	Modelli lineari	32
4.3.2	Alberi decisionali e Random Forest	33
4.3.3	Support Vector Machines	34
4.4	Deep Learning	34
4.4.1	Modelli sequence-based (CNN, RNN/LSTM)	35
4.4.2	Modelli graph-based (GNN)	36
4.4.3	Modelli attention-based e Transformer	38
5	ADMET	41
5.1	Il framework ADMET	41
5.2	La tossicità molecolare	41
5.3	Evoluzione verso il Machine Learning per la predizione ADMET . .	42
5.4	Multimodalità e meccanismi di Attention	43
6	State of the art	45
6.1	Some cool topic	45
7	Contribution	47
7.1	Fancy formulas here	47
		49
	Bibliography	49

List of Figures

2.1	Pipeline della Drug Discovery	4
3.1	Rappresentazione SMILES e struttura molecolare del Climbazolo. .	13
3.2	Flusso verticale del processo di trasformazione chimico-digitale da stringa SMILES a vettore di bit.	14
3.3	Confronto tra le notazioni per il benzene: SMILES (sopra) e SELF-IES (sotto) [KAB ⁺ 22].	15
3.4	Struttura chimica dell'Ibuprofene. Indici dei bit attivi rilevati: [74, 115, 123, 139, 141, 149, 154, 155, 157, 159, 160, 162, 163, 164, 165]	18
3.5	Primi 100 bit del fingerprint dell'Ibuprofene	18
3.6	Rappresentazione topologica non orientata $G = (V, E)$ dell'Ibuprofene generata da codice grazie a librerie RDKit e NetworkX.	20
3.7	Schema semplificato della rete neurale di AlphaFold. Adattato e modificato dall'opera originale di Jumper et al. (2021), disponibile in Open Access sotto licenza Creative Commons Attribution 4.0 International (http://creativecommons.org/licenses/by/4.0/).	23
4.1	Esempio schematico di un modello farmacoforico 3D. Sono evidenziati i punti di interazione chimica essenziali (sfere) e i rispettivi vincoli di distanza spaziale espressi in Å(Ångström).	31
6.1	Some random image	45

LIST OF FIGURES

List of Listings

3.1 Estrazione delle MACCS Keys tramite RDKit	17
3.2 Sequenza FASTA ufficiale della Prostaglandin G/H synthase 2 umana (UniProt P35354).	22
listings/HelloWorld.java	47

LIST OF LISTINGS

Chapter 1

Introduction

Write your intro here.

You can use acronyms that you defined previously, such as Internet of Things (IoT). If you use acronyms twice, they will be written in full only once (indeed, you can mention the IoT now without it being fully explained). In some cases, you may need a plural form of the acronym. For instance, that you are discussing Virtual Machines (VMs), you may need both VM and VMs.

Ventura Elettra: Add sidenotes in this way. They are named after the author of the thesis

Structure of the Thesis

Ventura Elettra: At the end, describe the structure of the paper

Chapter 2

Pipeline di sviluppo farmaceutico

2.1 Le fasi del Drug Development

Lo sviluppo di un nuovo farmaco è un processo complesso e delicato, che si articola in più fasi sequenziali, ciascuna delle quali introduce vincoli tecnici, economici e regolatori che rendono l'intero percorso lungo, dispendioso e ad alto rischio di fallimento [?]. In questo capitolo verrà analizzata questa pipeline di sviluppo e verranno sottolineate le criticità del percorso e come i nuovi *tools* informatici e tecnologici possono entrare in gioco per risolverle.

2.1.1 Target Prediction

L'identificazione di un bersaglio biologico rappresenta una delle sfide iniziali della pipeline di sviluppo di un farmaco. L'oggetto di questa ricerca è una molecola *target* che dimostra una particolare importanza nel contesto di una patologia, e di cui l'attività può essere "attaccata" o "drogata" da un farmaco, per ottenere un effetto terapeutico.

Storicamente, l'identificazione dei target si è basata su un processo sperimentale di *trial and error* e intuizione scientifica (basata quindi sulle conoscenze dei ricercatori). Tra gli approcci tradizionali più comunemente utilizzati si distinguono:

- **L'Affinity Pull-down** usato per isolare le proteine bersaglio tramite affinità specifica ad altre molecole "di prova" [?].




Figure 2.1: Pipeline della Drug Discovery

- Lo **screening knockdown** dell'intero genoma, volto a identificare il ruolo dei target tramite disattivazione genica [?].
- L'**High-Throughput Screening (HTS)**, screening ad alta velocità per l'analisi massiva di interazioni molecolari automatizzate [MBD⁺26].
- **Metodi sperimentali** ad alta precisione, come la **cristallografia a raggi X** o la **spettroscopia NMR**, che vengono tutt'ora impiegate per descrivere le interazioni ligando-proteine su scale più ridotte [KS26].

Tuttavia, questi approcci presentavano ostacoli significativi, che rendevano lo sviluppo di nuovi farmaci particolarmente dispendioso e inefficiente. Le cause principali di queste criticità sono spesso riconducibili a **bias soggettivi** dei ricercatori, che possono restringere eccessivamente lo spettro della *discovery* ed escludendo dal processo composti adeguati ma sconosciuti. Inoltre, la limitata scalabilità di questo tipo di approcci sperimentali impedisce la copertura dell'enorme spazio biochimico di candidati possibili (composto da tutte le combinazioni farmaco-target).

Rimane, oltre ai problemi riguardanti l'efficacia dei legami con il bersaglio, la questione della **druggability**. Oltre il 90% delle proteine umane è ancora poco conosciuto dal punto di vista strutturale [Fre] oppure è privo di opportuni *binding points* (o punti di legame) per l'agganciamento stabile di piccole molecole. Questi target vengono definiti "**Undruggable**".

Oggi l'**Intelligenza Artificiale** sta rivoluzionando questo campo, permettendo l'analisi sistematica di volumi enormi di dati biologici provenienti da fonti diverse, basandosi sul riconoscimento di schemi e pattern ricorrenti tra diverse patologie.

2.1.2 Dalla *target discovery* alla *hit generation*

Seguono le fasi di **drug discovery** vero e proprio, che si pongono l'obiettivo di identificare gli **hits**, farmaci in grado di interagire con i target precedentemente individuati. I geni candidati vengono espressi in grandi quantità in organismi poco complessi tramite la tecnologia del DNA ricombinante, permettendo lo **High-Throughput Screening (HTS)**, ovvero uno screening ad alta velocità che agisce su vaste e variegate librerie chimiche [KG23].

Sebbene l’HTS sia più performante in termini di costi rispetto ai metodi manuali, non si è dimostrato in grado di garantire la sicurezza o l’efficacia della molecola su organismi più complessi. Per superare tali limiti, emerge la necessità di tecniche di **Virtual Screening** (VS), che permettono di pre-selezionare *in silico* i composti più promettenti, riducendo drasticamente il numero di test fisici necessari.

2.1.3 Screening dei composti

Lo screening rappresenta lo strumento per ”setacciare” le librerie chimiche nella ricerca delle giuste interazioni biochimiche.

Il **VS** si distingue dall’HTS per la sua capacità di andare oltre i limiti della ricerca fisica attuabile in laboratorio, valutando computazionalmente composti appartenenti a librerie fisiche o sintetizzabili su richiesta [CL24]. Questo approccio si divide in due macro-famiglie:

- I metodi **ligand-based**, che si basano sull’ipotesi che molecole con proprietà simili a ligandi noti presentino attività biologica analoga. Tra questi, la **pharmacophore searching** identifica composti compatibili al target per caratteristiche chimico-spaziali (come la presenza di donatori e accettori di idrogeno o di gruppi aromatici in determinate posizioni) [McI07].
- I metodi **structure-based**, che sfruttano invece la struttura tridimensionale del target tramite strumenti come il **molecular docking** o l’**ensemble docking**. Quest’ultimo è un’evoluzione del primo che valuta il ligando su molteplici conformazioni del recettore, ottenendo così risultati più robusti rispetto all’approssimazione del recettore singolo e rigido.

Il virtual screening accelerato dal Machine Learning rappresenta una risposta al crescente e sempre più insostenibile peso computazionale del docking. Questo approccio prevede che un modello di ML venga addestrato sui risultati del docking su un sottoinsieme della libreria (si usano librerie dette ”ultra-large”) e che impari a predire i punteggi del docking per i composti incogniti, senza eseguire il calcolo fisico. Questo approccio può portare a una riduzione di 100 volte il numero di composti da sottoporre a docking esplicito, mantenendo comunque un arricchimento dei composti top-scoring paragonabile allo screening esaustivo [CL24].

La *hit discovery* è tuttavia solo il primo passaggio del processo di *lead generation*, o *Hit to Lead* (H2L), che si pone di valutare i composti individuati dalle *hits* non solo per la loro presenza di attività, ma per la qualità della loro interazione con il target. In questa fase vengono analizzate potenza, selettività e proprietà fisico-chimiche di base, causando una scrematura che può apportare un miglioramento del legame chimico hit-target dell'ordine di grandezza nanomolare [BGF⁺22]. La fase finale di drug discovery è la *Lead Optimization* (LO), che interviene per accentuare caratteristiche desiderate nei composti lead selezionati, o per correggere i difetti strutturali che impedirebbero ad essi di superare i trial clinici. La LO moderna è un processo razionale guidato da metodi computazionali che includono studi farmacoforici, docking molecolare (metodo utilizzato per prevedere l'orientamento di un ligando su un recettore per la formazione di un complesso stabile), dinamica molecolare (simulazioni con lo scopo di ottenere dati sulle proprietà fisico-strutturali delle molecole) e QSAR. In particolare, il **QSAR** (Quantitative Structure-Activity Relationship) rappresenta un approccio di modellazione statistica volto a correlare le caratteristiche strutturali con l'attività biologica dei composti, evolvendosi oggi in modelli di Machine Learning capaci di interpretare e prevedere queste caratteristiche per generare risultati nuovi [BGF⁺22].

Una volta ottenute le lead ottimizzate si può passare agli **studi pre-clinici**, condotti su modelli animali per valutare sicurezza ed efficacia dei farmaci, prima che questi vengano testati sull'essere umano. La fase successiva, quella degli effettivi **trial clinici**, si articola a sua volta in tre stadi progressivi:

- La fase I verifica la sicurezza del composto su un piccolo gruppo di soggetti sani;
- La fase II ne valuta l'efficacia su pazienti affetti dalla patologia interessata;
- La fase III, condotta su popolazioni più ampie, costituisce il test definitivo richiesto per l'approvazione regolatoria.

Al termine di questo percorso, il farmaco approvato entra nella fase di **post-market surveillance**, in cui vengono monitorati nel lungo periodo gli effetti collaterali e la stabilità della formulazione.

2.2 Attrition Rate e impatto economico

Il percorso che racchiude queste fasi è caratterizzato da un problema fondamentale: nonostante l'accelerazione in ambito tecnologico degli ultimi anni e la comparsa di nuovi strumenti computazionali ad ausilio del processo, il successo delle fasi cliniche rimane un obiettivo estremamente difficile da raggiungere. Questo fenomeno è descritto dall'**attrition rate**, ovvero il tasso di riduzione ("logoramento") del numero di candidati farmaci durante l'avanzamento della pipeline. Delle migliaia di molecole potenziali individuate dalla prima fase di discovery, solo una piccola frazione sopravvive ai test clinici e meno del 10% dei composti che entrano nel primo step di trial raggiunge l'approvazione finale dalle autorità regolatorie.

Questo elevato tasso di insuccesso si traduce in elevatissimi costi economici. Lo sviluppo di un nuovo farmaco richiede oggi un investimento medio di circa **2,6 miliardi di dollari americani** e un arco temporale compreso tra i dodici e i quindici anni [?]. Inoltre, anche il ritorno economico per le industrie farmaceutiche è drasticamente calato: nell'arco di un decennio, per ogni dollaro investito in ricerca il ritorno economico è crollato drasticamente, passando da 10 a meno di 2 centesimi [Fre].

Le cause di questo elevato tasso di fallimento sono molteplici. In primo luogo, molti farmaci per malattie comuni e con meccanismi biologici noti sono già stati scoperti; ciò che rimane da esplorare riguarda patologie più rare e complesse, dove l'identificazione di molecole target risulta più difficile [Fre]. Inoltre, la selezione delle molecole nelle fasi di *discovery* può essere basata su parametri troppo semplici e poco esaustivi. Infatti, come evidenziato da **Kenakin** [Ken24], la mancanza di efficacia clinica e i problemi di sicurezza legati alla tossicità rimangono le cause primarie del logoramento dei candidati farmaci, ed entrambi sono imputabili a una descrizione farmacologica superficiale e poco approfondita dei **lead** stessi.

2.3 Il ruolo dell'AI nella pipeline

L'integrazione dell'Intelligenza Artificiale (AI) e del Deep Learning (DL) ha trasformato la pipeline di ricerca farmaceutica da un processo basato su "trial and error" a un percorso più disciplinato, guidato dalla raccolta e dall'analisi dei dati bio-

logici [?]. Questi strumenti vengono impiegati trasversalmente, in ciascuna delle diverse fasi più delicate e "logoranti" del processo.

Nella fase di **target identification**, l'AI sta affiancando e in alcuni casi sostituendo i metodi tradizionali di screening, prima basati sull'analisi dettagliata dell'affinità tra molecole. Il nuovo approccio consiste nel rappresentare i geni per la loro *funzione biologica*, analogamente alle tecniche di *word embedding* sviluppate nel Natural Language Processing (NLP). Negli step successivi dello sviluppo del composto, il contributo più significativo si osserva nella predizione dei comportamenti di interazione farmaco-proteina (DPI). Queste stime sono solitamente compiute su uno spazio chimico di scala molto ampia, e richiedono l'analisi di molte interazioni ancora sconosciute. Proprio per questo, i modelli di Machine Learning vengono addestrati in modalità semi-supervisionato per etichettare queste interazioni incognite, integrando efficacemente informazioni eterogenee, quali la struttura chimica del composto, i dati genomici e le reti di interazione. L'importanza di affinare tali modelli risiede nella necessità di colmare il *knowledge gap* relativo agli effetti collaterali: è stato infatti stimato che circa 1.000 proteine umane siano potenzialmente responsabili di tossicità *off-target*.

Identificare precocemente queste interazioni impreviste risulta dunque fondamentale per prevedere e mitigare interazioni nocive già nelle fasi preliminari dello sviluppo in silico [?].

Chapter 3

Rappresentazione molecolare e machine readability

3.1 Lettura di dati chimici e biologici in informatica

L'applicazione di tecniche di Intelligenza Artificiale nell'ambito biochimico richiede il passaggio fondamentale da dati chimici a dati computazionali. Questi ultimi non devono essere semplicemente informazioni biologiche tradotte digitalmente, ma devono essere presentate in formati effettivamente elaborabili da algoritmi e tecnologie di ML [JPS22].

Storicamente, i risultati venivano registrati in forma cartacea, portando alla perdita di una vasta mole di dati non pubblicati. Al giorno d'oggi, invece, sebbene la quasi totalità degli strumenti di laboratorio sia in grado di rappresentare e salvare i dati in forma digitale (e accessibile ad altri ricercatori), una parte significativa di questi dati chimici resta in formati analogici o non accessibili automaticamente dagli agenti computazionali.

Risulta quindi necessaria, per sopperire a questa frammentazione di dati, una transizione verso una scienza più aperta, che integri l'implementazione di dati *machine-actionable*, ovvero adatti all'automatizzazione computazionale. In questo contesto, la rappresentazione molecolare deve raggiungere un *trade-off* tra completezza informativa e complessità. Infatti, sebbene formati altamente strutturati,

in grado di descrivere esaustivamente le proprietà chimiche, geometriche e funzionali delle molecole, si dimostrano ideali per modelli di ML, questi possono risultare estremamente onerosi per il lavoro dei chimici in laboratorio.

Senza una rappresentazione standardizzata che rispetti i principi **FAIR** (*Findable, Accessible, Interoperable, Reusable*), l'efficacia dei modelli di Deep Learning nella previsione delle proprietà molecolari risulterebbe superficiale rispetto alla complessità dei sistemi chimici e limitata dalla qualità del dato in ingresso, escludendo per esempio previsioni riguardo le condizioni di reazione o la sintetizzabilità [JPS22].


3.2 Rappresentazioni lineari: SMILES e SELFIES

La necessità di disporre di dati FAIR e *machine readable/actionable* ha portato allo sviluppo di diverse metodologie di codifica di dati chimici in formati meno complessi, processabili da algoritmi e metodi di machine learning.

3.2.1 SMILES

Il sistema **SMILES** (Simplified Molecular-Input Line-Entry System) rappresenta lo standard moderno più diffuso per la rappresentazione di molecole chimiche nell'ambito delle applicazioni di intelligenza artificiale.

Si basa sulla descrizione di strutture chimiche attraverso stringhe di caratteri alfanumerici ASCII [ATLO24], sottoponibili a processi NLP. Una stringa SMILES rappresenta la molecola come una catena di atomi, dove le ramificazioni sono indicate tra parentesi tonde, le chiusure degli anelli da numeri corrispondenti (per esempio, 1 con 1, ecc...), i simboli "-", "=", "#" [SBF⁺24] rappresentano diversi tipi di legame, mentre "@", "/", "\" diverse conformazioni isomeriche [ATLO24].



Le SMILES vengono tradotte in bit tramite *processing* a Fingerprint Molecolari:




Figure 3.1: Rappresentazione SMILES e struttura molecolare del Climbazolo.

Le stringhe entrano in input per passare in una prima **Fase di Scomposizione**, da cui si ottengono frammenti di natura diversa in base all'algoritmo usato (possono essere percorsi tra atomi, aree di intorno circolare, ecc...) [BBC⁺24].

Segue poi la fase di **Encoding**, in cui ogni frammento riceve un identificatore numerico basato sulle proprietà atomiche.

Infine la fase di **Hashing**, dove gli identificatori vengono mappati in un vettore di bit a dimensione fissa, tramite funzioni di hashing.

Nonostante la sua ampia diffusione, **SMILES** presenta criticità strutturali che ne limitano l'efficacia e lo rendono inadeguato agli strumenti computazionali moderni:

- Un primo limite della rappresentazione risiede nella **mancanza di univocità** che rende possibile la descrizione di una stessa molecola da molteplici stringhe diverse [LPP⁺24].
- Inoltre, il sistema SMILES è soggetto a una notevole fragilità sintattica che può portare facilmente all'invalidazione delle stringe a causa di piccole mutazioni di caratteri singoli (come una parentesi non chiusa), che rendono il complesso privo di significato biologico. Tale vulnerabilità risulta particolarmente problematica nell'uso di **Language Model** e modelli generativi, i quali producono combinazioni casuali di simboli durante la campionatura dello spazio latente.
- Infine, la natura lineare delle stringhe non permette di raffigurare correttamente la conformazione tridimensionale della molecola e le sue complesse




Figure 3.2: Flusso verticale del processo di trasformazione chimico-digitale da stringa SMILES a vettore di bit.

relazioni spaziali [UAL23].

3.2.2 SELFIES

Le stringhe **SELFIES** (SELF-referencing Embedded Strings) sono state progettate con lo scopo di superare i limiti di SMILES, garantendo una robustezza del 100% [KAB⁺22] ed eliminando gli errori sintattici derivati dalle variazioni di caratteri. Ogni stringa SELFIES valida corrisponde a una molecola valida, poiché la notazione si basa su una mappatura che impedisce violazioni dei vincoli fisici e strutturali. A differenza di SMILES, che è una notazione descrittiva, SELFIES è più simile a una libreria di stati finiti, i quali compongono una grammatica formale, un **automa** [LPP⁺24].

I SELFIES sono racchiusi tra parentesi quadre e definiscono, tramite identificatori locali, le ramificazioni e gli anelli in un unico punto, specificandone la lunghezza tramite *overloading*:

Quando il modello incontra un token di ramificazione o di anello, i numeri

immediatamente successivi vengono interpretati come dimensione della sottostruttura di riferimento [LPP⁺24]. In questo modo vengono evitati con successo variazioni indesiderate causate da riferimenti con indici lontani tra loro nella stringa.

Questa proprietà rende i SELFIES particolarmente adatti per l'impiego in modelli generativi, poiché l'intero spazio latente esplorato da questi sarebbe composto da strutture chimicamente valide, che non richiederebbero ulteriori filtri o controlli. In modelli come i **Variational Autoencoders** (VAE), ciò permette di usare un'ottimizzazione basata sulla **discesa del gradiente continua** per ottimizzare le proprietà molecolari con un dominio di dati validi e chimicamente sensati. [KAB⁺22].



Figure 3.3: Confronto tra le notazioni per il benzene: SMILES (sopra) e SELFIES (sotto) [KAB⁺22].

Nonostante i vantaggi tecnici offerti dalle stringhe SELFIES in termini di robustezza, il sistema **SMILES** rimane comunque lo standard cheminformatico più popolare per diverse ragioni; in particolare la sintassi SELFIES e il suo meccanismo di overloading dei token risulta più difficile da interpretare visivamente e meno intuitivo per gli operatori umani [LPP⁺24]. Inoltre, sorprendentemente, in alcuni task di classificazione, modelli basati su SMILES hanno mostrato di superare le controparti basate su SELFIES. Questo comportamento può essere dovuto al fatto che lo SMILES, essendo più sensibile alla tokenizzazione (generano sequenze di token più brevi ed efficienti per la stessa molecola), permette di catturare pattern unici, talvolta trascurati dai modelli SELFIES, che tendono invece a generalizzare eccessivamente le caratteristiche molecolari. Inoltre, questa maggiore compattezza permette ai **Transformer** di allocare la matrice di **attention** in modo più efficace, concentrandosi su un numero minore di unità informative [LPP⁺24].

3.3 Fingerprint molecolari

I *fingerprint* dall'altro canto adottano un approccio vettoriale: Come citato prima, la molecola viene decomposta in frammenti locali che vengono poi convertiti,

tramite funzioni di hashing, in un formato *machine-readable*, ovvero in un vettore numerico di lunghezza fissa (di solito pari a 1024 bit). Questi vettori codificano caratteristiche specifiche, come la presenza o l'assenza di determinate strutture (*binary fingerprints*) o il numero di occorrenze di determinati pattern molecolari (*count-based fingerprints*), permettendo agli algoritmi di ML di analizzare le molecole per task di *Virtual Screening* e previsione di proprietà biologiche [BBC⁺24].

Esistono diverse categorie principali di fingerprint, suddivise in base al tipo di informazione che catturano [BBC⁺24]:

- Fingerprints "**String-based**": Operano direttamente sulla stringa SMILES, frammentando la stringa in sottosequenze di dimensione fissa e calcolando il numero di occorrenze di questi frammenti.
- Fingerprints "**Path-based**": Data una rappresentazione **a grafo** della molecola (che verrà approfondita nella prossima sezione), vengono analizzati i **cammini lineari**, utilizzando, ad esempio, algoritmi come il **DFS (Depth First Search)**, che percorrono la molecola partendo da ogni singolo atomo fino ad una distanza di d legami, mantenendo un record di ogni percorso unico.
- Fingerprints **Farmacoforici**: Si focalizzano sulla reattività chimica piuttosto che sulla struttura scheletrica. I farmacofori sono l'insieme di caratteristiche chiave di una molecola all'interno del suo ambiente biochimico, come i punti di interazione, donatori/accettori, legami a idrogeno, gruppi idrofobici, ecc... Questi fingerprints codificano il modo in cui la molecola interagisce con l'ambiente circostante, concentrandosi maggiormente sulle proprietà funzionali, piuttosto che sulla struttura anatomica esatta.
- Fingerprints "**Substructure-based**": Basati sulla presenza di sottostrutture chimiche predefinite. Questo tipo di fingerprints utilizza un "dizionario" di frammenti noti, precedentemente individuati da esperti.
- Fingerprints **Circolari**: Partendo da un atomo, l'algoritmo di fingerprint aggrega le informazioni degli atomi vicini tra loro entro un raggio crescente, di fatto scomponendo la molecola in frammenti sullo stesso arco. Si tratta della

tecnica più utilizzata per i modelli di Machine Learning, poiché è in grado di catturare informazioni sull'ambiente locale dell'atomo in modo strutturato ed esaustivo.

3.3.1 Esempi di fingerprints

Alcuni esempi appartenenti alla categoria di rappresentazione con **fingerprint molecolari** sono le **Morgan fingerprints** (o *Extended Connectivity Fingerprints* (ECFP)) e le **MACCS key**.

Le prime si distinguono come strumento fondamentale e standard *de facto* per la codifica dei composti farmaceutici *drug-like*.

Queste fingerprints **circolari**, con lunghezza pari a 1024 bit, sono in grado di costruire dinamicamente i frammenti delle sottostrutture molecolari, a partire dalla loro rappresentazione a grafo [BBC⁺24].

Le **MACCS key (Molecular Access System)**, invece, si basano su un approccio più storico e utilizzano, come suggerito dal nome, un **dizionario** statico predefinito di sottostrutture, da cui attingere per codificare le strutture:

Sono rappresentate da un vettore binario da **166** bit di lunghezza. Ognuno di questi bit codifica la assenza/presenza (0,1) di una specifica caratteristica strutturale, definita tramite i pattern **SMARTS** (SMILES Arbitrary Target Specification) [BBC⁺24] [UAL23] che identificano, all'interno del dizionario, frammenti, gruppi funzionali o motivi molecolari.

Le stringhe SMILES vengono quindi utilizzate per costruire la sintassi dei fingerprints MACCS key, rendendo la rappresentazione della molecola più estesa e arricchita, e con maggiori dettagli sulla struttura.

Listing 3.1: Estrazione delle MACCS Keys tramite RDKit

```
1  from rdkit import Chem
2  from rdkit.Chem import MACCSkeys
3
4  smiles = "CC(C)Cc1ccc(cc1)C(C)C(=O)O"
5  mol = Chem.MolFromSmiles(smiles)
6  maccs_key = MACCSkeys.GenMACCSKeys(mol)
7  bit_string = maccs_key.ToBitString()
8
9  maccs_166 = [int(b) for b in bit_string][1:]
```




Figure 3.4: Struttura chimica dell'Ibuprofene.

Indici dei bit attivi rilevati: [74, 115, 123, 139, 141, 149, 154, 155, 157, 159, 160, 162, 163, 164, 165]

Vettore MACCS Key (Primi 100 bit in matrice 10x10)										
0	0	0	0	0	0	0	0	0	0	0
10	0	0	0	0	0	0	0	0	0	0
20	0	0	0	0	0	0	0	0	0	0
30	0	0	0	0	0	0	0	0	0	0
40	0	0	0	0	0	0	0	0	0	0
50	0	0	0	0	0	0	0	0	0	0
60	0	0	0	0	0	0	0	0	0	0
70	0	0	0	1	0	0	0	0	0	0
80	0	0	0	0	0	0	0	0	0	0
90	0	0	0	0	0	0	0	0	0	0
	+0	+1	+2	+3	+4	+5	+6	+7	+8	+9

Figure 3.5: Primi 100 bit del fingerprint dell'Ibuprofene

Nonostante i fingerprint molecolari offrano diversi vantaggi significativi rispetto alle rappresentazioni lineari, specialmente in termini di efficienza computazionale e interpretabilità, questi presentano una perdita di informazioni non trascurabile durante il loro processo di codifica *hashing*, soprattutto per quanto riguarda i dati sulla connettività dei frammenti [UAL23]. È quindi necessario risalire a una **ricostruzione lossless** (senza perdita di informazioni), invertendo la traduzione dei fingerprint. Si tratta di un processo computazionale basato sull'architettura **Transformer**, che viene utilizzata come un sistema di traduzione in grado di apprendere le dipendenze globali tra input (i bit del fingerprint) e output (token di stringhe molecolari molecolari), grazie al meccanismo di *multi-head attention*. Il modello riesce quindi a decodificare i fingerprint strutturali riconducendoli a rappresentazioni lineari univoche (SMILES o SELFIES) [UAL23].

3.4 Rappresentazione a grafo

La rappresentazione a **grafo** costituisce l'approccio più intuitivo e fedele alla realtà fisica per la digitalizzazione delle strutture chimiche, superando i limiti informativi delle notazioni lineari e minimizzando la perdita di dati.

La molecola viene rappresentata come un grafo non orientato $G = (V, E)$ [WLBF23], in cui:

Nodi (V): Rappresentano gli atomi della molecola.

Archi (E): Rappresentano i legami chimici interatomici.

Tale struttura permette di codificare direttamente la topologia (informazioni bidimensionali, come i legami covalenti) e la connettività della molecola (la geometria, le informazioni tridimensionali), trasformando le proprietà del composto in **matrici** elaborabili da modelli di Intelligenza Artificiale.

Per essere interpretata dai computer, la struttura del grafo viene convertita in matrici, convertendo così la informazioni chimiche in un linguaggio matematico adatto ad essere appreso dai modelli [WZ25].

Questa rappresentazione è il pilastro fondamentale per le **GNN (Graph Neural Networks)**, argomento che verrà affrontato nel prossimo capitolo.




Figure 3.6: Rappresentazione topologica non orientata $G = (V, E)$ dell’Ibuprofene generata da codice grazie a librerie RDKit e NetworkX.

3.5 Embedding molecolari e modelli pre-addestrati

L’**embedding molecolare** è un’operazione fondamentale nella ricerca farmaceutica. Questo processo consiste nel trasformare le informazioni relative al contesto strutturale e chimico di una molecola in una **rappresentazione numerica**, tipicamente sotto forma di vettori densi ad alta dimensione.

Questa pratica si basa su un’ipotesi di base: **tutte le molecole strutturalmente simili, presentano comportamenti e proprietà altrettanto simili**. Seguendo questa ipotesi, l’embedding cerca di mappare queste molecole in punti vicini nello spazio vettoriale [SBF⁺24].

I vettori di embedding possono essere generati principalmente in due modi distinti:

- **Embedding basati su Grafi** (come ad esempio i **GNN**). Gli embedding vengono estratti dalla struttura a grafo tramite le fasi di *update* dei nodi-atomo e di *message passing* [WKL⁺23]. In particolare, per ogni atomo u , viene calcolato l’embedding $h_u^{(t+1)}$ (con t che rappresenta il livello corrente

del *message passing*) aggregando i messaggi dai nodi vicini v . Durante il passaggio dei messaggi vengono inoltre integrate le caratteristiche dei legami chimici rappresentati dagli archi della GNN, x_{uv} . Durante la fase di *readout*, gli embedding di tutti i nodi vengono aggregati:

$$\hat{y} = R(\{h_u^{(L)} | u \in \mathcal{V}\})$$

Il risultato è un vettore riassuntivo degli embedding molto ricchi calcolati nei vari livelli della rete, che sarà usato per compiere predizione sulla molecola nel suo complesso, integrando le informazioni sulle sottostrutture e la sua topologia.

- **Embedding basati su stringhe (LLM)**. Sfruttano le rappresentazioni lineari testuali come **SMILES** per effettuare la codifica in vettori, catturando le informazioni semantiche e contestuali [SBF⁺24]. Questo processo avviene tramite tokenizzazione delle stringhe SMILES da parte di **Large Language Models** (che sono in grado di processarle in quanto dati in formato testuale), che vengono quindi elaborati dall'architettura a **Transformer**.

Per verificare la qualità dell'embedding estratto si utilizzano i **modelli di probe**, ovvero semplici classificatori lineari addestrati su vettori fissi, che sono in grado di verificare le informazioni catturate.

Un embedding di alta qualità dovrebbe essere in grado di rappresentare correttamente **proprietà topologiche**, **proprietà nello spazio** e **sottostrutture molecolari**.

3.6 Rappresentazione delle proteine target: FASTA

Oltre alle piccole molecole, è necessario anche rappresentare in modo corretto le sequenze amminoacidiche che compongono i target terapeutici.

Lo standard **FASTA** è un formato testuale ampiamente utilizzato per questo task. La struttura primaria della proteina viene codificata come una stringa lineare di caratteri simbolici in cui ogni lettera corrisponde a un amminoacido specifico [WLX⁺26]. Essendo unidimensionale però, questo formato di rappresentazione

non è adatto a cogliere gli aspetti più importanti delle sequenze proteiche, ovvero la loro conformazione tridimensionale.

Nel contesto dell'analisi sequence-based, la stringa in formato FASTA rappresenta l'input standard per i modelli predittivi di Deep Learning, come vedremo nei capitoli successivi. Di seguito viene riportata la sequenza primaria nativa del target biologico **COX-2** umano, estratta dal database di riferimento **UniProt** (ID: P35354):

Listing 3.2: Sequenza FASTA ufficiale della Prostaglandin G/H synthase 2 umana (UniProt P35354).

```
1 >sp|P35354|PGH2_HUMAN Prostaglandin G/H synthase 2 OS=Homo sapiens OX=9606 GN=
  PTGS2 PE=1 SV=2
2 MLARALLLCAVLALSHTANPCCSHPCQNRGVCMSVGFDQYKCDCTRITGFYGENCSTPEFL
3 TRIKLFLKPTPNTVHYILTHFKGFNVVNNIPFLRNAIMSYVLTSRSHLIDSPPTYNADY
4 GYKSWEAFSNLSYYTRALPPVPDDCPTPLGVKGKKQLPDSNEIVEKLLLRKFIPDPQGS
5 NMMFAFFAQHFTHQFFKTDHKRGPAFTNGLGHGVLDLNIHYGETLWARHRELREQEVTMYS
6 VNYKNGVLRIIDYEPMDFLELLWPRDLKYIIDGVEIVKNPHSIPTLLQYIQMKMKIIPNL
7 LYLNPFPTLSSLYILPDKSGFQNKIYARTQAPLSVVEIDYLPIDYVSPPTGLNVALF
8 TLNLYVMLWPRNLIFVFFLMSTIFVFLKTRKMNLIFLFFIFVFLMRVIVMLWPRNLYVMF
9 FFLMSTIFVFLKTRKMNLIFLFFIFVFLMRVIVK
```

3.6.1 AlphaFold

Si tratta di una tecnologia di Intelligenza Artificiale che permette la predizione della conformazione 3D di una proteina, a partire solo dalla sua sequenza FASTA 1D [MBD⁺26].

Questa tecnologia, sviluppata da **DeepMind**, ha segnato un importante punto di svolta nel campo della biologia computazionale, superando i limiti di oltre 50 anni di ricerca precedenti [JEP⁺21].

Viene sfruttata un'architettura a rete neurale per integrare le nozioni chimico-fisiche e biologiche all'interno di un insieme di regole di conformazione proteica. Il modello si divide in due fasi principali:

1. **Evoformer:** Primo modulo incaricato delle previsione della struttura. Si approccia al problema computazionale interpretandolo come un **problema di inferenza di grafi** nello spazio tridimensionale. Tiene traccia degli amminoacidi propensi a mutare insieme, e a creare quindi strutture di avvol-




Figure 3.7: Schema semplificato della rete neurale di AlphaFold. Adattato e modificato dall'opera originale di Jumper et al. (2021), disponibile in Open Access sotto licenza Creative Commons Attribution 4.0 International (<http://creativecommons.org/licenses/by/4.0/>).

gimento complesse, tramite **Multiple Sequence Alignments** o **MSA**. Queste sono collezioni di sequenze di proteine omologhe allineate tra loro in un array bidimensionale, la cui analisi risulta utile per predire coordinazioni tra amminoacidi e siti di ripiegamento proteico [JEP⁺21].

2. **Modello di Struttura:** Trasforma le informazioni ricavate dall'Evoformer in coordinate 3D reali. Ogni amminoacido è trattato come un corpo rigido indipendente, o "residue gas", che può ruotare e traslare nello spazio fino ad assumere la sua posizione "corretta" all'interno della conformazione della catena proteica. Viene usato un meccanismo di **Attenzione (Invariant Point Attentio, o IPA)** le cui iterazioni raffinano le informazioni spaziali degli elementi.

Il successo straordinario di AlphaFold, che ha portato alla vittoria del Premio Nobel per la Chimica nel 2024, rappresenta uno degli esempi più lampanti del potenziale dell'Intelligenza Artificiale applicata alle scienze della vita. Lo stacco netto tra la qualità della ricerca prima e dopo l'introduzione di AlphaFold dimostra come il Deep Learning non sia più un mero strumento computazionale sussidiario di ottimizzazione, ma un vero e proprio motore di scoperta scientifica, capace di raggiungere straordinari traguardi.

Chapter 4

DTI e DTA: Predizione delle interazioni Farmaco-Bersaglio

4.1 Il problema computazionale

Una delle fasi più complesse della pipeline è la corretta predizione delle interazioni biochimiche tra il target (precedentemente identificato nella fase di *target prediction*) e i possibili farmaci candidati. Tradizionalmente affrontata tramite costosi esperimenti di laboratorio (*wet-lab*) questa fase può essere ricondotta a un problema computazionale ben definito: determinare se, e con quale intensità, una determinata piccola molecola d è in grado di legarsi e interagire con una proteina target t .

Dal punto di vista dell'apprendimento automatico, il problema viene formalizzato attraverso una **funzione di interazione** (o funzione di **scoring**).

$$f(d, t) \rightarrow y \tag{4.1}$$

Che mappa la coppia farmaco-target (d, t) in un esito di interazione y . L'algoritmo ha il compito di filtrare lo spazio chimico come segue:

data una proteina t (*target*), il modello esplora un dataset massivo di sequenze molecolari $\{d_1, d_2, \dots, d_n\}$ per identificare quelle che massimizzano la **funzione di scoring**. Questi valori calcolati permettono di creare un *ranking* dei potenziali composti candidati e delle interazioni più potenzialmente efficaci. Questo processo

è il passaggio cruciale della ricerca farmacologica moderna da problema sperimentale biochimico a problema di **ottimizzazione** e ricerca in uno **spazio latente** a dimensionalità alta.

A seconda della natura dell'output y , il problema può essere articolato in due formulazioni principali:

- **Classificazione Binaria** $\{0,1\}$, se il modello fornisce un output booleano, che indica la assenza/presenza di interazione con il target [MBD⁺26].
- **Regressione**, se il modello ritorna un valore continuo che quantifica la forza di legame, ovvero la **Drug-Target Affinity (DTA)**.

4.1.1 DTI: classificazione binaria

Nel task di **Drug-Target Interaction (DTI)**, l'obiettivo è determinare se esiste o meno un'interazione tra la coppia (d, t) . Il modello produce in output un'etichetta discreta $y \in \{0,1\}$ e viene addestrato minimizzando una funzione di perdita di classificazione, tipicamente la *binary cross-entropy* [AOH26].

4.1.2 DTA: regressione del livello di affinità

Nel task di **Drug-Target Affinity (DTA)**, il problema viene riformulato come un compito di **regressione**:

L'obiettivo è la stima quantitativa dell'energia libera di legame (ovvero l'affinità di legame) prevista tra farmaco e proteina-bersaglio [MBD⁺26]. Il modello restituisce un valore continuo $\in \mathbb{R}$ corrispondente a parametri biologici (misurabili sperimentalmente) come la **costante di dissociazione** (K_d), la **costante di inibizione** (K_i) o la **concentrazione inibente** (IC_{50}). Una volta calcolati, questi valori vengono convertiti in scala logaritmica per ridurre la varianza e stabilizzare la convergenza durante la fase di *training* dei modelli di Deep Learning [KS26].

4.1.3 Matrice di interazione e DTI Network

Sia D lo spazio chimico dei farmaci, e T lo spazio biologico dei target, l'insieme delle relazioni tra i due può essere formalizzato attraverso una **matrice di interazione**

farmaco-bersaglio (DTI matrix) [MBD⁺26], in cui le righe rappresentano i ligandi, mentre le colonne rappresentano i bersagli biologici. Di conseguenza, ogni cella $M_{i,j}$ contiene il valore dell'interazione tra il farmaco i -esimo e il target j -esimo (in formato binario per la DTI e come valore continuo nella DTA).

Questo tipo di rappresentazione presenta tuttavia una problematica strutturale: le matrici di interazione sono infatti estremamente **sparse**, a causa del fatto che la maggior parte delle coppie d - t non sono mai state testate sperimentalmente e non si hanno quindi informazioni a riguardo. Per superare tale limite, si ricorre a tecniche di *Matrix Factorization* avanzate, come la *Neighbourhood Regularized Logistic Matrix Factorization (NRLMF)*, che decompongono la matrice in componenti latenti per identificare pattern nascosti e prevedere interazioni sconosciute [MBD⁺26].

Tuttavia, questo approccio tratta la matrice come un oggetto isolato e non sfrutta le relazioni strutturali tra i composti stessi, come la **similarità** chimica o funzionale tra molecole. Per integrare questo tipo di informazioni, le DTI matrix vengono reinterpretate come le matrici di adiacenza di una **DTI Network**.

Si tratta di un **modello di rete bipartita eterogenea**, in cui i nodi di una partizione (composti) sono collegati ai nodi dell'altra (target) tramite archi che rappresentano le interazioni note tra i due. Questa riformulazione supera la staticità della matrice “piatta” e permette di modellare le relazioni intra-partizione, oltre a quelle farmaco-target, arricchendo ulteriormente il quadro informativo per la predizione [MBD⁺26].

Modelli di ML supervisionato come il *Bipartite Local Model* (BLM) sfruttano questa struttura per costruire dei classificatori *locali* specifici per ogni nodo della rete. A differenza di modelli globali che analizzano la rete nella sua interezza, il BLM addestra un classificatore separato per ogni farmaco e ogni target, rifacendosi alle interazioni nel *neighbourhood* del nodo come segnale supervisionato. Questa strategia permette di catturare pattern specifici dei protagonisti dell'interazione, che i modelli globali generalizzerebbero eccessivamente.

4.2 Metodologie di Predizione

L'obiettivo è la costruzione di un modello che, in seguito ad un addestramento, sia in grado di fare generalizzazioni su coppie farmaco-target mai osservate prima, stimando correttamente la probabilità di interazione e la sua intensità.

Queste metodologie si differenziano in base al tipo di informazione su cui si basano:

- I metodi **ligand-based**, tra cui rientrano i modelli **QSAR** (*Quantitative Structure-Activity Relationship*), che associano le proprietà strutturali di un determinato composto con la sua attività biologica. Storicamente implementati tramite modelli lineari, i modelli QSAR si sono nel tempo evoluti verso modelli di ML e DL di complessità ed efficienza maggiore, rimanendo comunque di natura *ligand-based*. Anche la **modellazione farmacoforica** fa parte di questa categoria, e serve ad identificare le caratteristiche strutturali minime di un composto per ottenere l'interazione desiderata con il bersaglio, stringendo il cerchio di possibili candidati (risulta particolarmente utile nei casi in cui la struttura 3D della proteina non è ricavabile [MBD⁺26]).
- I metodi **structure-based** che, al contrario dei precedenti, richiedono la conoscenza della struttura 3D della proteina target, al fine di simulare l'interazione chimica. Il rappresentante principale di questa categoria è il **docking molecolare**, che verrà trattato nella sezione successiva (section 4.2.1).
- I metodi **network-based**, comprendono la DTI network e il modello BLM, già citati in precedenza. Questi rappresentano i farmaci e i target attraverso i nodi di un grafo e sfruttano la topologia della rete per analizzare nuove connessioni/interazioni.
- I metodi basati su **Machine Learning** e **Deep Learning**, infine, rappresentano lo stato dell'arte. I modelli di ML classico apprendono pattern complessi a partire da descrittori progettati manualmente, mentre le architetture di DL estraggono automaticamente le informazioni facendo affidamento solo al dataset di input, senza richiedere *feature engineering*. Entrambi verranno trattati in dettaglio più avanti.

4.2.1 Metodi ligand-based e structure-based

I modelli computazionali per la predizione delle interazioni farmaco-bersaglio si dividono in due paradigmi: I metodi **ligand-based**, che operano unicamente sulle proprietà chimiche del farmaco, e i metodi **structure-based**, che richiedono la conoscenza della struttura tridimensionale del target [AOH26]. I primi sono preferiti quando la struttura proteica non è disponibile; i secondi offrono una comprensione più profonda dell'interazione, ma richiedono una rappresentazione più complessa e informazioni aggiuntive sui composti.

QSAR e modelli farmacoforici

I modelli **QSAR** (*Quantitative Structure-Activity Relationship*) stabiliscono una relazione matematica (di tipo statistico) tra i descrittori delle proprietà chimiche di un composto e la sua attività biologica di ligazione [MBD⁺26].

Si basano spesso su un principio di **somiglianza chimica** (*"guilt-by-association"*), per il quale molecole tra loro strutturalmente simili tendono a mostrare attività biologiche affini [MBD⁺26]. Per predire correttamente la somiglianza, il modello tradizionalmente utilizza regressioni lineari noti per la loro semplicità e interpretabilità. Per far ciò però, è necessario tradurre le molecole in parametri quantitativi da poter usare come *feature* nella predizione [ONCE24]. Questi **descrittori molecolari** sono essenziali per caratterizzare correttamente la struttura e il comportamento dei composti e possono essere "estratti" dalle rappresentazioni molecolari in modi diversi:

- Estrazione classica di **descrittori "hand-crafted"**, in cui vengono usati software specializzati (RDKit, PaDEL-Descriptor, ecc... [AOH26]) modellati secondo regole chimiche predefinite. Queste *features* vengono classificate in base alla loro dimensionalità [ONCE24].
 - **0D e 1D**: derivano dalla formula molecolare e sono tipicamente un semplice conteggio dei gruppi funzionali più rilevanti.
 - **2D**: descrittori topologici, sono estratti solitamente da rappresentazioni a grafo e descrivono la connettività e la ramificazione di questo.

- **3D**: descrivono il volume, l'area superficiale, i potenziali elettrostatici e altre caratteristiche spaziali e geometriche.
 - **Di dimensionalità superiore**: integrano informazioni aggiuntive come la flessibilità di conformazione del ligando, l'adattamento strutturale del target e l'effetto del solvente sulle interazioni molecolari.
 - **Molecular Fingerprints**: unico caso in cui non è necessaria un'estrazione, la rappresentazione a vettore binario è sufficiente per descrivere in modo dettagliato i pattern complessi.
- **Deep Representation Learning**, che sfrutta algoritmi di Deep Learning per apprendere i predittori ("deep descriptors") a partire dalle rappresentazioni. Per esempio, vengono usate le CNN per estrarre pattern chimici dalle stringe testuali SMILES/SELFIES, oppure vengono usati modelli linguistici (PLM) per cogliere descrittori ad alta dimensione dopo un addestramento su dataset di sequenze rappresentative [AOH26] [KYMD25]. La Deep Representation Learning è alla base dell'utilizzo di DL per i task di DTI e DTA, come vedremo più nel dettaglio nelle sezioni successive.

Il limite dei modelli QSAR rimane legato ai limiti della regressione lineare (o più semplicemente ai limiti di un task basato su relazioni di somiglianza), ovvero l'affidabilità del modello è circoscritta al dominio di applicabilità [AOH26] definito dal *training set*. Non è garantita la qualità su set di dati nuovi e mai visti prima dal modello.

I **Modelli Farmacoforici** complementano il QSAR con una visione geometrica dell'interazione. Sono definiti come una rappresentazione astratta della disposizione spaziale e delle caratteristiche **stereoelettroniche** (combinazione tra le geometria tridimensionale e le proprietà di carica della molecola) di una molecola [KSSL22]. Queste caratteristiche sono necessarie per il riconoscimento della molecola da parte del target definendo le "condizioni indispensabili" dirette per formare un legame. Una volta identificate le proprietà, queste vengono modellate come sfere o vettori in uno spazio tridimensionale, fornendo una "mappa" del sito di legame.




Figure 4.1: Esempio schematico di un modello farmacoforico 3D. Sono evidenziati i punti di interazione chimica essenziali (sfere) e i rispettivi vincoli di distanza spaziale espressi in Å (Ångström).

Docking molecolare

Il **docking molecolare** è il principale metodo *structure-based* per la predizione dell'affinità farmaco-bersaglio. Il suo funzionamento si basa sulla simulazione del posizionamento del ligando all'interno del sito di legame, in modo da cercare la conformazione più favorevole [FFZ19]. Per questo, a differenza dei metodi *ligand-based* ha bisogno di conoscere la struttura tridimensionale della proteina target.

Il processo si articola in due fasi distinte [AOH26]:

Per prima vi è la fase di **pose prediction**, in cui viene esplorato lo spazio di conformazione del ligando attraverso **algoritmi di ricerca** (per esempio il *simulated annealing* con AutoDock).

Succede poi la fase di **scoring** in cui vengono valutate e classificate le pose tramite l'apposita funzione, che pesa i contributi delle interazioni tra gruppi chimici.

A seconda della flessibilità delle molecole, inoltre, il Docking viene suddiviso in due tipologie di classi [FFZ19]:

- **Rigid Docking:** in cui entrambe le entità del legame sono fisse (viene di solito utilizzata per le macromolecole).

- **Flexible-Rigid Docking:** in cui il recettore è fisso mentre il ligando è flessibile.
- **Flexible Docking:** o "Soft" Docking, dove entrambi i componenti sono flessibili. Sono docking più precisi ma con un costo computazionale decisamente maggiore, dato che richiedono la mappatura di tutte le configurazioni possibili.

Il limite principale del Docking tradizionale è proprio la sua scarsa scalabilità, data dal suo elevato costo computazionale. Il costo del docking per una singola coppia ligando-recettore lo rende inadatto ad analisi su librerie di composti molto elevate, che sono l'ambito richiesto dai problemi di DTA. Per questo motivo si scelgono algoritmi in grado di "passare in rassegna" dataset molto grandi in modo efficiente, e si fanno uso sempre di più di tecniche AI-enhanced e di Machine Learning.

4.3 Machine Learning Classico

Le metodologie computazionali per la predizione di interazioni farmaco-target hanno seguito un processo evolutivo motivato dalle limitazioni riportate dalle generazioni precedenti. I primi approcci si basavano su descrittori delle proprietà molecolari dei composti progettati manualmente e basati unicamente sulle competenze e conoscenze scientifiche degli esperti di laboratorio.

4.3.1 Modelli lineari

I modelli di ML tradizionale si basano spesso sulla *feature engineering* manuale, eseguita prima dell'addestramento del modello da ricercatori incaricati di selezionare le caratteristiche descrittive delle molecole, ovvero le loro proprietà fisico-chimiche. Tra questi approcci si distinguono i **Modelli Lineari** [ONCE24]:

- **MLR (Multiple Linear Regression)**
- La regressione dei **minimi quadrati parziali (PLS)**
- La **Regressione Lineare Bayesiana (RLB)**

Questi rappresentano tecniche statistiche in grado di generare una funzione lineare che descrive il legame tra i descrittori molecolari (le variabili x , dette “indipendenti”) e l’esito della predizione, ovvero l’affinità di legame (variabili y , “dipendenti”) [ONCE24]. In questo modo, il modello è capace di calcolare come i cambiamenti nelle proprietà dei composti influenzino l’attività biologica di essi. Diventa quindi possibile prevedere il comportamento di nuovi composti da analizzare, semplicemente “consultando” la linea di regressione e inserendo i nuovi parametri nella funzione.

Il limite di questi modelli, tuttavia, risiede proprio nella loro possibilità di catturare unicamente relazioni lineari, escludendo quindi pattern di interazione più complessi.

4.3.2 Alberi decisionali e Random Forest

Per superare questo ostacolo di complessità subentrano metodi più avanzati, come **Random Forest** e gli **alberi di decisione (DT)**, che sono in grado di ricavare dai dati relazioni complesse, rappresentabili da funzioni non-lineari.

I **DT** sono una struttura dati ad albero in cui i dati vengono ricorsivamente partizionati in sottoinsiemi in base a caratteristiche specifiche come, in questo caso, particolari proprietà molecolari. In questo modo i rami della struttura rappresentano i possibili esiti del problema di classificazione/regressione (in base al tipo di task che viene affrontato, DTI o DTA). Una volta “riempito”, il DT può essere usato come modello predittivo, in grado di classificare nuovi composti in base al loro percorso guidato dalla radice fino alle foglie dell’albero [ONCE24]. Queste tecniche sono efficaci e facili da interpretare, ma soffrono di **overfitting**: indeed, questi modelli tendono a “memorizzare” le caratteristiche dei dati del *training set*, senza realmente apprendere dei pattern per generalizzare il comportamento dei vari input. In questo modo, le prestazioni risultano eccellenti durante la fase di training ma abbastanza scarse durante la fase di test o l’identificazione di nuovi dati.

La **Random Forest (RF)** è una tecnica di *ensemble learning* progettata per ridurre il fenomeno di overfitting. È composta da più DT combinati e addestrati su sottoinsiemi differenti del dataset generale. La decisione finale avviene tramite

voto di maggioranza, nel caso della DTI, o tramite media, nel caso della DTA.

4.3.3 Support Vector Machines

Oltre agli algoritmi *tree-based*, sono utilizzate anche tecniche come **Support Vector Machines (SVM)**. Queste affrontano la classificazione DTI cercando, all'interno dello spazio dei descrittori, l'**iperpiano di separazione** con margine massimo tra coppie in interazione e non interagenti. L'iperpiano ottimale è quello che massimizza la distanza tra i punti più vicini di ciascuna delle due classi, infatti più il margine è ampio e migliore sarà la capacità del modello di fare previsioni su coppie mai osservate. Questi punti "di confine" vengono chiamati **vettori di supporto** e garantiscono la stabilità del sistema [MLMLC22].

Per gestire la non-linearità delle proprietà biologiche, SVM ricorre al **kernel trick**, che "solleva" i dati di una dimensione, garantendo sempre la separazione lineare. Il kernel non necessita delle coordinate dei punti nello spazio, ma ricava direttamente il loro **prodotto scalare** calcolandolo in uno spazio a dimensionalità superiore [MLMLC22].

Il limite strutturale comune a tutti gli approcci di ML tradizionale è la dipendenza della predizione dalla qualità dei descrittori selezionati [AOH26]. L'inadeguatezza delle proprietà molecolari in esame può compromettere il lavoro del modello indipendentemente dalla sua potenza di calcolo o dalla sua efficienza. Questo vincolo è proprio la motivazione del passaggio verso le architetture di **Deep Learning**, in grado di apprendere in modo autonomo le informazioni dai dataset.

4.4 Deep Learning

Il subentro del **Deep Learning** ha affrontato i problemi di DTI e DTA come un **task di apprendimento supervisionato**: il modello apprende la funzione

$$f(d, t) \rightarrow y \tag{4.2}$$

in grado di generalizzare su coppie drug-target non osservate, riconoscendo pattern chimici e biologici di alta complessità. Invece di ricevere parametri calcolati man-

ualmente, questi modelli ricavano le caratteristiche più informative direttamente dai dati “grezzi”, siano questi stringhe SMILES, sequenze amminoacidiche o grafi molecolari [WLX⁺26].

4.4.1 Modelli sequence-based (CNN, RNN/LSTM)

I modelli *sequence-based* affrontano il problema DTI trattando direttamente le stringhe SMILES o i fingerprint del farmaco e le sequenze delle proteine come dati testuali unidimensionali, senza richiedere input formalizzati “su misura” [TZYL24].

CNN:

Le **CNN** o **Reti Neurali Convoluzionali** rappresentano una delle prime architetture DL applicate con successo a questo tipo di input biologico. Nascono principalmente per processare dati in formato a griglia come i pixel nelle immagini, ma possono essere adottate in ambito di predizione DTI e DTA per lavorare su task di QSAR, tramite **convoluzione unidimensionale** [ONCE24]. Il processo si divide in tre fasi principali che seguono i diversi strati della rete:

- **Layers Convoluzionali**, che scansionano le sequenze dei composti e ricercano al loro interno dei pattern strutturali locali, detti *motif*. Il risultato del passaggio attraverso questi strati è la composizione di una matrice **feature map**, che indica le feature estratte e il grado di certezza nella loro rilevazione.
- **Layers di Pooling**, che riducono la dimensionalità delle feature map ottenute, riassumendo solo le informazioni più importanti e utili per la previsione di nuovi composti. Questo step, oltre a rendere il modello più leggero, è fondamentale per la riduzione del *noise*, ovvero informazioni superflue che potrebbero compromettere il risultato del procedimento con piccole variazioni di misurazione e impurità nei dati.
- **Layers Fully Connected**, infine, sono strati densi che combinano tra loro le caratteristiche apprese dalle mappature nei livelli precedenti, per generare una previsione finale.

Questo tipo di reti neurali sono facilmente scalabili e molto efficienti ma, facendo uso di informazioni 1D, fanno anch'esse fatica ad incorporare strutture tridimensionali più complesse e a catturare le dipendenze biochimiche tra elementi [HLY⁺25].

RNN:

Le **RNN (Recurrent Neural Networks)** sono un'altra architettura di Deep Learning progettata per l'elaborazione di dati sequenziali. A differenza delle CNN, però, queste reti non sono in grado di modellare in modo corretto e affidabile le dipendenze tra atomi tra loro distanti [WLX⁺26].

Operano mantenendo un **layer nascosto**, che si evolve con l'elaborazione della sequenza di input. Nel contesto della predizione di interazioni con il target farmacologico, le RNN, come le CNN, analizzano efficacemente le stringhe SMILES dei composti per apprendere i **motifs** strutturali e i pattern nelle relazioni che determinano l'affinità di legame.

4.4.2 Modelli graph-based (GNN)

I modelli *sequence-based*, anche se risultano più semplici nella formattazione degli input e più facilmente scalabili, faticano a prendere conoscenza del contesto tridimensionale del sito di legame [WLX⁺26]. Questa perdita di informazioni può essere superata grazie alla rappresentazione a grafo tipica dei modelli trattati in questa sezione.

Come accennato brevemente nel capitolo precedente, questo tipo di rappresentazione permette l'elaborazione dei contesti da parte delle **GNN (Graph Neural Networks)**, che operano simulando la topologia e le relazioni spaziali reali dei composti chimici (legami tra atomi *intra* e *inter* composto) propagando informazioni tra i nodi tramite il meccanismo di *message passing*. Questo processo avviene in due passaggi iterativi [WLBF23]:

- **Computazione e Aggregazione:** Il modello calcola un messaggio elaborando le caratteristiche del nodo centrale, con quelle dei nodi e degli archi ad esso adiacenti.

- **Aggiornamento:** Lo stato del nodo viene aggiornato integrando il nuovo messaggio con la sua informazione precedente.

Queste informazioni elaborate vengono poi lette tramite l'operazione di **Read-out**. Attraverso un meccanismo simile al pooling, le caratteristiche di tutti i nodi vengono aggregate e aggiornate in un unico vettore di caratteristiche globali, in grado di rappresentare lo stato dell'intera molecola [WLBF23].

In generale, nel contesto di drug discovery le GNN stanno rivoluzionando il concetto di tradizionale **Computer-Aided Drug Design** (CADD), trasformando il processo in una ricerca automatizzata. Queste architetture consentono di esplorare lo spazio chimico per generare e ottimizzare (come nella *Lead Optimization*) nuove entità molecolari, apportando migliorie nelle proprietà desiderate, come bioattività, stabilità e sintetizzabilità. Queste permettono anche uno studio precoce di proprietà ADMET e della tossicità, portando a una riduzione drastica di fallimenti nei test clinici [WZ25].

Nel contesto del problema computazionale DTI/DTA, le GNN risultano fondamentali nello screening virtuale per prevedere con efficienza le affinità di legame tra farmaci e target attraverso l'implementazione di architetture a doppia branca (*dual-branch*). In questo paradigma, il problema predittivo viene convertito in un compito di fusione di informazioni estratte in parallelo da due grafi distinti:

- **Branca del Farmaco (d):** La piccola molecola viene convertita in un grafo molecolare in cui gli atomi rappresentano i nodi (caratterizzati da proprietà chimiche come numero atomico, valenza, ecc...) e i legami chimici costituiscono gli archi. Algoritmi come le *Graph Convolutional Networks* (GCN) scansionano questa struttura per estrarre pattern locali e stereochimici stabili.
- **Branca del Target (t):** La proteina viene modellata come un grafo di contatto dei residui. In questa struttura, i nodi rappresentano i singoli amminoacidi, mentre gli archi vengono tracciati tra nodi la cui distanza euclidea nello spazio 3D è inferiore a una determinata soglia, preservando la topologia del sito di legame [AOH26].

Una volta che i messaggi sono stati propagati all'interno delle rispettive strutture, le operazioni di *readout* generano **due vettori di feature ad alta dimensionalità**. Questi vettori vengono successivamente combinati all'interno di un modulo di interazione, spesso arricchito da meccanismi di attenzione (*Graph Attention Networks* - GAT) per pesare l'importanza relativa dei vari atomi e residui nel complesso farmaco-bersaglio [ÖRA⁺26]. Il vettore risultante viene infine processato da strati *Fully Connected* per mappare l'interazione nell'output finale y , traducendosi in una classificazione booleana per i task di DTI o in un valore continuo di affinità (K_d , K_i , IC_{50}) per i task di DTA.

4.4.3 Modelli attention-based e Transformer

Le architetture basate sul meccanismo di **attenzione** e sui **Transformer** rappresentano l'attuale stato dell'arte nella predizione di DTI e DTA. Il loro punto di forza principale risiede nella capacità di catturare **dipendenze a lungo raggio** all'interno delle sequenze molecolari e proteiche [AOH26] [MBD⁺26], superando il limite strutturale delle CNN e delle RNN, che tendono a perdere il contesto globale quando le sequenze diventano molto lunghe.

Il meccanismo di attenzione

L'*attention* si basa sulla premessa che non tutte le parti di una sequenza sono ugualmente rilevanti per una previsione. Si rende quindi necessario **pesare selettivamente** le sottosequenze più informative, ad esempio, applicato alle interazioni farmaco-bersaglio, i residui amminoacidici del sito di legame, ignorando le regioni che non contribuiscono all'interazione.

Architetture Transformer per DTI e DTA

I **Transformer** estendono il meccanismo di attention trattando le stringhe SMILES e le sequenze amminoacidiche (FASTA) come se fossero un linguaggio naturale da interpretare. A differenza delle RNN, che elaborano i token uno alla volta in modo sequenziale, i Transformer processano l'intera sequenza simultaneamente, rendendo il training più efficiente e la cattura del contesto globale più affidabile [WLX⁺26].

Tra i modelli più rappresentativi si distinguono:

- **MolTrans** e **MT-DTI**, che applicano encoder Transformer sia al farmaco che alla proteina per apprendere rappresentazioni consapevoli del contesto. Questi modelli mostrano ottime prestazioni anche in scenari *cold-start*, ovvero in presenza di coppie farmaco-target nuove mai osservate durante il training [MBD⁺26].
- **TC-DTA**, un modello ibrido che adotta un encoder Transformer per la sequenza proteica e una CNN per la rappresentazione del farmaco, ottimizzando l'estrazione di informazioni semantiche dagli amminoacidi pur mantenendo l'efficienza computazionale della rete convoluzione per il lato molecolare [TZYL24].
- **FusionDTI**, che integra token strutturali proteici e stringhe SELFIES tramite Transformer, con l'obiettivo di ottenere predizioni a grana fine sul sito di legame specifico.

Graph Transformer

Un'ulteriore evoluzione consiste nell'applicare la logica dei Transformer direttamente alle strutture a grafo delle molecole, dando origine ai cosiddetti **Graph Transformer**. Questi modelli incorporano nei meccanismi di *attention* informazioni strutturali specifiche del grafo, come la **centralità dei nodi** e le **distanze spaziali** tra atomi, che le GNN standard non sfruttano in modo esplicito. Il modello **GraphormerDTI** rappresenta un esempio di questa categoria applicata al problema DTI, dimostrando miglioramenti rispetto alle GNN classiche grazie all'integrazione di queste feature informative strutturali nell'attenzione [KS26].

Modelli linguistici pre-addestrati (PLM)

I Transformer costituiscono la spina dorsale dei cosiddetti **Foundation Models**, ovvero modelli pre-addestrati su database massivi in modalità auto-supervisionata e successivamente adattati a compiti specifici tramite *fine-tuning*. Questo paradigma *pre-train / fine-tune* permette di sfruttare la conoscenza biochimica e chimica gen-

erale acquisita su larga scala verso i task di DTI e DTA con dataset di dimensioni più ridotte [WLX⁺26].

Vantaggi e limiti

Uno dei punti di forza più rilevanti di questi modelli in ambito farmacologico e/o medico è la loro **interpretabilità**: i pesi di attenzione possono essere visualizzati attraverso delle **mappe di attenzione**, che indicano quali atomi o residui hanno guidato maggiormente la predizione [KS26]. Questo strumento offre ai ricercatori la possibilità di **validare biologicamente** il risultato computazionale, verificando se le regioni evidenziate corrispondono a siti di legame noti.

Il principale limite rimane la **complessità computazionale**: l'*attention* ha complessità quadratica rispetto alla lunghezza della sequenza, il che rende il training particolarmente oneroso in termini di tempo e memoria quando si lavora con sequenze proteiche molto lunghe [MBD⁺26]

Chapter 5

ADMET

La valutazione delle proprietà **ADMET** (Assorbimento, Distribuzione, Metabolismo, Escrezione e Tossicità) è considerata un passaggio critico all'interno della pipeline di sviluppo farmacologico, al fine di ridurre "a monte" i tassi di fallimento nelle fasi cliniche. Infatti, la scorretta valutazione di queste proprietà rappresenta un incremento nel rischio di logoramento dei farmaci candidati.

5.1 Il framework ADMET

L'impiego del Machine Learning in questo campo rappresenta un'importante svolta metodologica rispetto ai test empirici tradizionali [?], poiché permette di processare grandi volumi di dati molecolari per prevederne il comportamento farmacocinetico con costi e tempi drasticamente ridotti, allargando il primo "collo di bottiglia" del processo di ricerca.

In questo nuovo contesto, il framework ADMET non viene più interpretato come una serie di test isolati, ma come un sistema integrato di vincoli biochimici che si influenzano a vicenda e che determinano la sicurezza di una molecola.

5.2 La tossicità molecolare

TO-DO

5.3 Evoluzione verso il Machine Learning per la predizione ADMET

Storicamente, i primi tentativi di razionalizzare le proprietà e l'attività biologica delle molecole si basava su metodi come *quantitative structure-activity relationship* (QSAR) e *structure-activity relationship* (SAR). Tuttavia questi metodi presentavano un limite fondamentale: la necessità di una selezione manuale e di un'accurata rappresentazione delle *feature* chimiche. Con l'avvento del ML classico, tuttavia, l'attenzione si è spostata verso l'uso di rappresentazioni come i *chemical fingerprints*, che vengono presi come input da algoritmi come **Random Forest**, **Support Vector Machines**, **k-Nearest Neighbors** e **XGBoost**. Questi ultimi hanno permesso di apprendere classificazioni complesse, trattando la molecola come un vettore binario che indica presenza/assenza di frammenti chimici, e raggiungendo risultati in modo veloce e con processi parzialmente interpretabili. Tuttavia, questi algoritmi ignorano la struttura tridimensionale e la connettività delle molecole, e le leggono invece come una sequenza di caratteristiche booleane, rendendo le interazioni tra frammenti vicini nello spazio ma lontani nella stringa di difficile predizione.

Per una predizione più accurata di queste interazioni più complesse, **Li et al. (2026)** propongono un modello chiamato **CMA**, ovvero "Cross-Aligned Multimodal Attention". L'idea centrale è proprio quella di rappresentare la molecola come in un **attention cross-modale**, ovvero tramite tre le matrici Query (Q), Key (K) e Value (V) del meccanismo di attention dei Transformer. Ogni matrice viene mappata a partire da una rappresentazione diversa, e solo una di queste fa riferimento ai *fingerprints*:

- Query utilizza **GROVER**, un algoritmo che decodifica informazioni sulla struttura delle molecole in un grafo in cui ogni nodo rappresenta un atomo e i legami chimici sono astratti come archi. GROVER è un **GNN** (Graph Neural Networks) preaddestrato su 10 milioni di molecole e permette la rappresentazione più ricca strutturalmente. Contribuisce a circa il 36% della contribuzione media finale.
- Value viene processata da **ResNet-50**, una CNN in grado di estrarre im-

magini molecolari bidimensionali e catturare così la forma, la simmetria e l'arrangiamento degli atomi dei soggetti candidati. La rete viene preaddestrata su 10 milioni di molecole. Contribuisce a circa il 22% della contribuzione media finale.

- Key, infine, fa uso di **fingerprint MACCS**, composta da 166 bit che codifica l'occorrenza di gruppi chimici specifici. Contribuisce a circa il 42% della contribuzione media finale.

La funzione di punteggio di Attention è definita come segue:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

La modalità Query "interroga" la modalità Key per determinare quali elementi siano più rilevanti all'interno del contesto corrente. Il risultato è infine un media pesata dalla modalità Value. Tradotto nell'ambito molecolare, la rappresentazione a grafo può interrogare le *fingerprint* per comprendere al meglio quali siano le caratteristiche strutturali locali più coerenti con la topologia generale, mentre il risultato finale viene modulato dalle immagini estratte da ResNet. [?]

5.4 Multimodalità e meccanismi di Attention

Chapter 6

State of the art

I suggest referencing stuff as follows: fig. 6.1 or Figure 6.1

6.1 Some cool topic




Figure 6.1: Some random image

Chapter 7

Contribution

You may also put some code snippet (which is NOT float by default), eg: chapter 7.

7.1 Fancy formulas here

```
1 public class HelloWorld {
2     public static void main(String[] args) {
3         // Prints "Hello, World" to the terminal window.
4         System.out.println("Hello, World");
5     }
6 }
```

Bibliography

- [AOH26] Bilal Ahmad, Khmaies Ouahada, and Habib Hamam. Machine learning for drug-target interaction prediction: A comprehensive review of models, challenges, and computational strategies. *Computational and Structural Biotechnology Journal*, 31:316–345, January 2026.
- [ATLO24] Nicholas Aksamit, Alain Tchagang, Yifeng Li, and Beatrice Ombuki-Berman. Hybrid fragment-SMILES tokenization for ADMET prediction in drug discovery. *BMC bioinformatics*, 25(1):255, August 2024.
- [BBC⁺24] Davide Boldini, Davide Ballabio, Viviana Consonni, Roberto Todeschini, Francesca Grisoni, and Stephan A. Sieber. Effectiveness of molecular fingerprints for exploring the chemical space of natural products. *Journal of Cheminformatics*, 16(1):35, March 2024.
- [BGF⁺22] Mariana Pegrucci Barcelos, Suzane Quintana Gomes, Leonardo Bruno Federico, Isaque Antonio Galindo Francischini, Lorane Izabel da Silva Hage-Melim, Guilherme Martins Silva, and Carlos Henrique Tomich de Paula da Silva. Lead Optimization in Drug Discovery. In Carlton A. Taft and Sergio R. de Lazaro, editors, *Research Topics in Bioactivity, Environment and Energy: Experimental and Theoretical Tools*, pages 481–500. Springer International Publishing, Cham, 2022.
- [CL24] Jens Carlsson and Andreas Lutten. Structure-based virtual screening of vast chemical space as a starting point for drug discovery. *Current Opinion in Structural Biology*, 87:102829, August 2024.

- [FFZ19] Jiyu Fan, Ailing Fu, and Le Zhang. Progress in molecular docking. *Quantitative Biology*, 7(2):83–89, June 2019.
- [Fre] David H Freedman. Hunting for New Drugs with AI.
- [HLY⁺25] Jingjing Hou, Zixin Li, Mengjun Yang, Binjie Wang, Bing Wang, and Xiaohui Yang. DGCA-DTA: A Deep Graph Neural Network Based on Co-Attention for Drug Target Affinity Prediction. *IEEE Transactions on Computational Biology and Bioinformatics*, 22(5):2093–2104, September 2025.
- [JEP⁺21] John Jumper, Richard Evans, Alexander Pritzel, Tim Green, Michael Figurnov, Olaf Ronneberger, Kathryn Tunyasuvunakool, Russ Bates, Augustin Žídek, Anna Potapenko, Alex Bridgland, Clemens Meyer, Simon A. A. Kohl, Andrew J. Ballard, Andrew Cowie, Bernardino Romera-Paredes, Stanislav Nikolov, Rishub Jain, Jonas Adler, Trevor Back, Stig Petersen, David Reiman, Ellen Clancy, Michal Zielinski, Martin Steinegger, Michalina Pacholska, Tamas Berghammer, Sebastian Bodenstein, David Silver, Oriol Vinyals, Andrew W. Senior, Koray Kavukcuoglu, Pushmeet Kohli, and Demis Hassabis. Highly accurate protein structure prediction with AlphaFold. *Nature*, 596(7873):583–589, August 2021.
- [JPS22] Kevin Maik Jablonka, Luc Patiny, and Berend Smit. Making the collective knowledge of chemistry open and machine actionable. *Nature Chemistry*, 14(4):365–376, April 2022.
- [KAB⁺22] Mario Krenn, Qianxiang Ai, Senja Barthel, Nessa Carson, Angelo Frei, Nathan C. Frey, Pascal Friederich, Théophile Gaudin, Alberto Alexander Gayle, Kevin Maik Jablonka, Rafael F. Lameiro, Dominik Lemm, Alston Lo, Seyed Mohamad Moosavi, José Manuel Nápoles-Duarte, AkshatKumar Nigam, Robert Pollice, Kohulan Rajan, Ulrich Schatzschneider, Philippe Schwaller, Marta Skreta, Berend Smit, Felix Strieth-Kalthoff, Chong Sun, Gary Tom, Guido Falk von Rudorff, Andrew Wang, Andrew D. White, Adamo

- Young, Rose Yu, and Alán Aspuru-Guzik. SELFIES and the future of molecular string representations. *Patterns*, 3(10), October 2022.
- [Ken24] Terry Kenakin. Know your molecule: Pharmacological characterization of drug candidates to enhance efficacy and reduce late-stage attrition. *Nature Reviews Drug Discovery*, 23(8):626–644, August 2024.
- [KG23] Monalisa Kesh and Sachin Goel. Target-Based Screening for Lead Discovery. In Mithun Rudrapal and Johra Khan, editors, *CADD and Informatics in Drug Discovery*, pages 141–173. Springer Nature, Singapore, 2023.
- [KS26] Sheo Kumar and Amritpal Singh. Predicting drug-target interactions and binding affinity using an optimized deep learning approach. *Journal of Computer-Aided Molecular Design*, 40(1):84, March 2026.
- [KSSL22] Stefan Michael Kohlbacher, Matthias Schmid, Thomas Seidel, and Thierry Langer. Applications of the Novel Quantitative Pharmacophore Activity Relationship Method QPhAR in Virtual Screening and Lead-Optimisation. *Pharmaceuticals*, 15(9):1122, September 2022.
- [KYMD25] Mahesh Koirala, Lindy Yan, Zoser Mohamed, and Mario DiPaola. AI-Integrated QSAR Modeling for Enhanced Drug Discovery: From Classical Approaches to Deep Learning and Structural Insight. *International Journal of Molecular Sciences*, 26(19):9384, September 2025.
- [LPP⁺24] Miguelangel Leon, Yuriy Perezhohin, Fernando Peres, Aleš Popović, and Mauro Castelli. Comparing SMILES and SELFIES tokenization for enhanced chemical language modeling. *Scientific Reports*, 14(1):25016, October 2024.
- [MBD⁺26] Hiranmoy Mondal, Amlan Bishal, Biplab Debnath, Aakriti Patel, Joy Das, and Tahreen Taj. AI-driven drug–target interaction prediction: Current progress, challenges, and future roadmap for precision

- medicine. *Journal of Computer-Aided Molecular Design*, 40(1):89, March 2026.
- [McI07] Campbell McInnes. Virtual screening strategies in drug discovery. *Current Opinion in Chemical Biology*, 11(5):494–502, October 2007.
- [MLMLC22] Osva Antonio Montesinos López, Abelardo Montesinos López, and Jose Crossa. Support Vector Machines and Support Vector Regression. In Osva Antonio Montesinos López, Abelardo Montesinos López, and José Crossa, editors, *Multivariate Statistical Machine Learning Methods for Genomic Prediction*, pages 337–378. Springer International Publishing, Cham, 2022.
- [ONCE24] Adeshina I. Odugbemi, Clement Nyirenda, Alan Christoffels, and Samuel A. Egieyeh. Artificial intelligence in antidiabetic drug discovery: The advances in QSAR and the prediction of α -glucosidase inhibitors. *Computational and Structural Biotechnology Journal*, 23:2964–2977, July 2024.
- [ÖRA⁺26] Gökhan Özsari, Ahmet Süreyya Rifaioğlu, Aybar Can Acar, Tunca Doğan, and M. Volkan Atalay. DTA-GNN: A toolkit for constructing target-specific drug–target affinity datasets and training graph neural networks. *SoftwareX*, 34:102671, June 2026.
- [SBF⁺24] Shaghayegh Sadeghi, Alan Bui, Ali Forooghi, Jianguo Lu, and Alioune Ngom. Can large language models understand molecules? *BMC Bioinformatics*, 25(1):225, June 2024.
- [TZYL24] Xiwei Tang, Yiqiang Zhou, Mengyun Yang, and Wenjun Li. TC-DTA: Predicting Drug-Target Binding Affinity With Transformer and Convolutional Neural Networks. *IEEE Transactions on NanoBioscience*, 23(4):572–578, October 2024.
- [UAL23] Umit V. Ucak, Islambek Ashyrmamatov, and Juyong Lee. Reconstruction of lossless molecular representations from fingerprints. *Journal of Cheminformatics*, 15(1):26, February 2023.

- [WKL⁺23] Hanchen Wang, Jean Kaddour, Shengchao Liu, Jian Tang, Joan Lasenby, and Qi Liu. Evaluating Self-Supervised Learning for Molecular Graph Embeddings. *Advances in Neural Information Processing Systems*, 36:68028–68060, December 2023.
- [WLBF23] Yuyang Wang, Zijie Li, and Amir Barati Farimani. Graph Neural Networks for Molecules. In Chen Qu and Hanchao Liu, editors, *Machine Learning in Molecular Sciences*, pages 21–66. Springer International Publishing, Cham, 2023.
- [WLX⁺26] Yike Wang, Jingwei Lv, Yan Xia, Junlin Xu, Yajie Meng, Feifei Cui, Leyi Wei, Quan Zou, and Zilong Zhang. A unified survey on drug-target interaction and binding affinity prediction: Models, representations, and challenges. *Biotechnology Advances*, 88:108843, May 2026.
- [WZ25] Rui Wang and Chunlin Zhuang. Graph neural networks driven acceleration in drug discovery. *Acta Pharmaceutica Sinica B*, 15(12):6163–6177, December 2025.

Acknowledgements

Optional. Max 1 page.